Conocimiento oculto en la accidentalidad vial de Colombia: modelos supervisados, agrupamiento de municipios y análisis de comentarios de YouTube

Danna Angelika Ruiz Rodríguez, Laura Danniela Botia Ordoñez, Nicolás Gutiérrez Reyes y Luz Angela Gómez Galindo

Facultad de Ingeniería, Universidad de Cundinamarca, Extensión Chía

Minería de Datos: Etapa 6, Conocimiento oculto

Docente: Edison Gustavo Cañón Varela

13 de noviembre de 2026

Tabla de contenido

Productos entregados.....4

Introducción.....4

Contexto, objetivo y preguntas de análisis.....5

Descripción de los datos y transformaciones realizadas.....6

Origen de los datos.....6

Transformaciones adicionales para Orange.....7

Flujos de Orange, widgets y conexiones.....9

Modelos supervisados.....12

Planteamiento del problema.....12

Relevancia de las variables.....14

Modelos y parámetros.....15

Evaluación con validación cruzada.....17

Validación temporal.....24

Interpretación del modelo seleccionado.....27

Selección del modelo.....28

Limitaciones.....29

Agrupamiento de municipios.....29

Pregunta, unidad de análisis y variables.....29

Algoritmo y elección del número de grupos.....32

Caracterización de los grupos.....38

Patrones ocultos y apoyo a decisiones.....43

Comentarios de YouTube.....43

Conexión a la API de YouTube....43
Criterios de búsqueda y selección de videos....46
Extracción y restricciones....49
Preparación y limpieza....50
Análisis de los comentarios en Orange....53
Aporte de los comentarios frente a los datos....65
Conclusiones integradas....66
Hipótesis que requieren validación....68
Decisiones que pueden apoyarse en los resultados....68
Limitaciones generales....69
Evidencias del trabajo en el repositorio y publicación....69
Referencias....75
Anexo A. Ejecución y reproducibilidad....77

Productos entregados

Este informe técnico es el documento de entrega de la Etapa 6. Los productos que lo acompañan pueden consultarse en los enlaces de la Tabla 1.

Tabla 1

Enlaces de acceso a los productos de la Etapa 6

Producto	Enlace
Repositorio del proyecto (GitHub)	https://github.com/lawiwi/Accidentalidad-Seguridad-Vial
Aplicación Flask publicada	https://nicolacito.dpdns.org/
Sección «Conocimiento Oculto» de la aplicación	https://nicolacito.dpdns.org/conocimiento-oculto/
Video de sustentación (YouTube)	https://youtu.be/1QD2VBmOwFs

Nota. El informe en PDF también puede consultarse y descargarse desde la sección «Conocimiento Oculto», que además integra el video de sustentación.

Introducción

En las etapas anteriores el equipo describió la población de vehículos involucrados en accidentes de tránsito con víctimas, evaluó y trató la calidad de los datos, presentó los conocimientos evidentes en tableros de Power BI y organizó la información en un modelo estrella para cruzarla desde varias dimensiones. Esos análisis respondieron preguntas sobre *cuánto*, *dónde* y *cuándo*, pero dejaron abiertas otras que no se resuelven con conteos: qué combinación de factores hace más probable que un vehículo termine en un siniestro con muertos, qué municipios comparten un mismo patrón de riesgo aunque estén lejos entre sí, y qué piensan las personas sobre las causas de los siniestros.

Esta sexta etapa aborda esas preguntas con técnicas de minería de datos en Orange Data Mining (Demšar et al., 2013). Sobre los 406.540 registros del modelo estrella se compararon tres modelos supervisados —regresión logística, Random Forest y Naive Bayes— para anticipar la gravedad del siniestro, y se agruparon 248 municipios con k-Means según la composición de su

flota siniestrada, la antigüedad de los vehículos y la autoridad que atiende los siniestros. Como complemento, se extrajeron 18.685 comentarios de 21 videos de YouTube mediante la API oficial y se analizaron con técnicas de minería de texto para contrastar los hallazgos con la percepción ciudadana.

El documento presenta, en orden, el contexto y las preguntas, los datos y sus transformaciones, los flujos de Orange, la implementación y evaluación de los modelos supervisados, el agrupamiento de municipios, el procedimiento de extracción y análisis de los comentarios, las conclusiones integradas, las limitaciones y las evidencias del repositorio y de la publicación en la aplicación Flask. Cada captura se acompaña de una explicación, las figuras y tablas siguen las normas APA (American Psychological Association [APA], 2020), y el Anexo A reúne los comandos necesarios para reproducir el trabajo.

Contexto, objetivo y preguntas de análisis

En las etapas anteriores el equipo construyó, depuró e integró la información de vehículos involucrados en siniestros viales publicada en Datos Abiertos Colombia. Primero se diagnosticó la calidad de los datos, luego se aplicó un proceso ETL con SQL Server Integration Services, después se presentaron los conocimientos evidentes en tableros de Power BI y, en la Etapa 5, se organizó la información en un modelo estrella para el análisis multidimensional. Esos resultados describen *cuánto* y *dónde*, pero no explican qué combinación de factores hace más probable un desenlace fatal ni qué territorios comparten un mismo patrón de riesgo.

El objetivo de esta etapa es descubrir patrones, relaciones y comportamientos que profundicen la comprensión del problema mediante modelos de aprendizaje supervisado y no supervisado en Orange Data Mining, y complementar esos hallazgos con el análisis de

comentarios extraídos a través de la API de YouTube. Para ello se formularon tres preguntas de análisis:

1. **Pregunta supervisada.** ¿Se puede anticipar si un vehículo involucrado pertenece a un siniestro con muertos a partir de su tipo, edad, marca, departamento, autoridad que registra el hecho y mes?
2. **Pregunta de agrupamiento.** ¿Qué perfiles de municipio existen según la composición de su flota siniestrada, la antigüedad de los vehículos y la autoridad que atiende los siniestros, y cómo se relacionan esos perfiles con la letalidad?
3. **Pregunta de texto.** ¿Qué causas, responsables y soluciones mencionan los ciudadanos al comentar noticias sobre siniestros viales en Colombia, y en qué coinciden o se diferencian de lo que muestran los datos?

Descripción de los datos y transformaciones realizadas

Origen de los datos

La fuente original es el conjunto de datos «Vehículos involucrados en un accidente de tránsito» que el Ministerio de Transporte publica en Datos Abiertos Colombia (Ministerio de Transporte, 2026). Para esta etapa se usó la tabla de hechos *FactVehiculoAccidente* del modelo estrella de la Etapa 5, almacenada como réplica en *modelo_multidimensional/dw/dw_accidentalidad_vial.sqlite*. Cada registro corresponde a un vehículo involucrado en un siniestro con víctimas, en un mes y municipio, e incluye las dimensiones de tiempo, ubicación, tipo de vehículo, marca, antigüedad, autoridad de tránsito y gravedad. El periodo cubierto va de enero de 2022 a febrero de 2026 y suma 406.540 registros.

Transformaciones adicionales para Orange

Orange no realiza uniones entre tablas, por lo que se escribió el script *scripts/preparar_datos_orange.py*, que lee el modelo estrella y genera archivos en el formato nativo *.tab*. Las transformaciones aplicadas, adicionales a las de etapas anteriores, fueron las siguientes:

- **T1. Aplanamiento.** Se unió la tabla de hechos con sus siete dimensiones para obtener una tabla plana.
- **T2. Agrupación de tipos de vehículo poco frecuentes.** Los tipos con menos de 800 registros (maquinaria agrícola e industrial, cuadriciclos y similares) se agruparon en la categoría «Otro (maquinaria/especial)», lo que deja 13 categorías.
- **T3. Reducción de marcas.** Se conservaron las 15 marcas más frecuentes y las demás se agruparon en «Otras marcas», pasando de 361 a 16 categorías.
- **T4. Variables redundantes como meta.** CategoriaVehiculo, GrupoEdad, Region y Trimestre se derivan de otra predictora; Anio solo se usa para la partición temporal; IdRegistro y Municipio son identificadores. Todas quedan visibles, pero no entran a los modelos.
- **T5. Prevención de fuga de información.** Se excluyó la columna VehiculoAccidenteConMuertos, que es la misma variable objetivo codificada como 0 y 1.
- **T6. Formato con roles.** Los archivos *.tab* incluyen tres filas de encabezado (nombre, tipo y rol), de modo que Orange reconoce automáticamente la variable objetivo y las metas.

- **T7. Perfil municipal.** Para el agrupamiento se calcularon porcentajes por municipio sin usar la gravedad; el porcentaje de vehículos en siniestros con muertos se guardó solo como meta para caracterizar los grupos después de formarlos.

Con estas transformaciones se generaron cinco archivos, todos ubicados en *data/orange/*, en la misma carpeta que los flujos de Orange:

Tabla 2

Archivos de datos generados para Orange

Archivo	Registros	Uso
vehiculos_gravedad_completo.tab	406.540	Población completa (no se publica por su tamaño; se regenera con el script)
vehiculos_gravedad_muestra100k.tab	100.000	Validación cruzada de los modelos supervisados
vehiculos_entrenamiento_2022_2024.tab	85.032	Entrenamiento de la validación temporal
vehiculos_prueba_2025_2026.tab	14.968	Prueba de la validación temporal
perfil_municipios.tab	248	Agrupamiento de municipios

Nota. La muestra de 100.000 registros es estratificada por gravedad con semilla 42, por lo que conserva la proporción de la población (5,08 % con muertos). Con la población completa la regresión logística obtiene un AUC de 0,820, prácticamente igual al de la muestra.

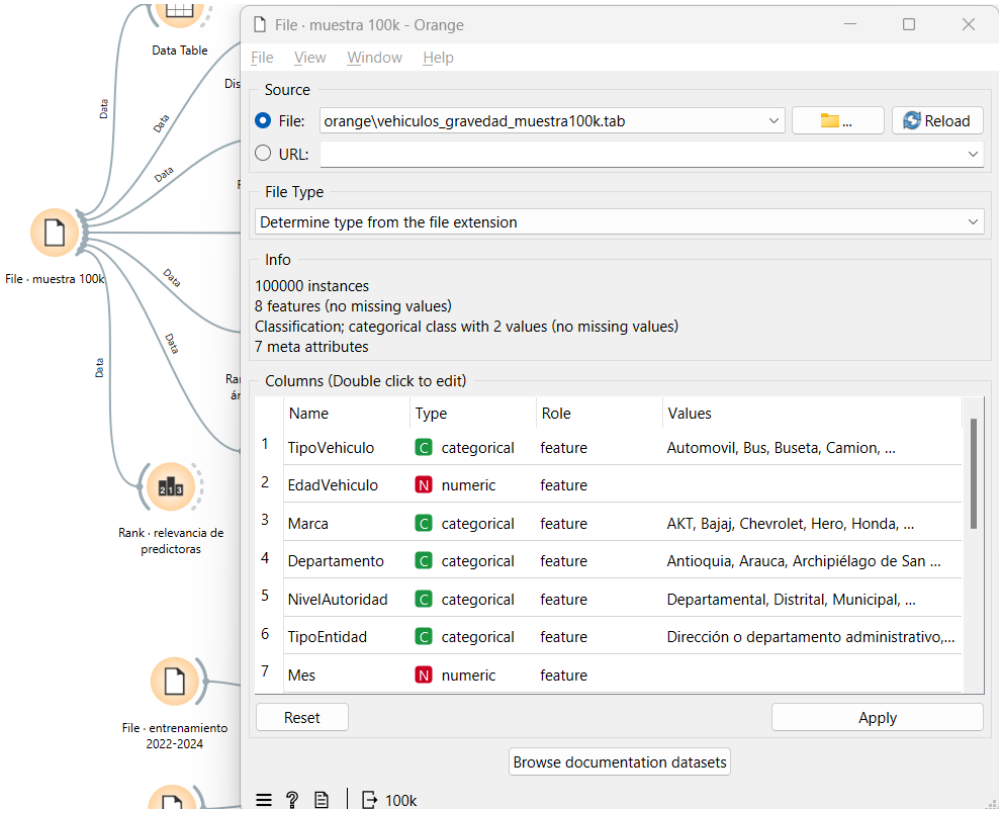
Tabla 3

Variables del ejercicio supervisado

Papel	Variable	Tipo	Descripción
Objetivo	Gravedad	Discreta (2)	Con Heridos / Con Muertos
Predictora	TipoVehiculo	Discreta (13)	Tipo de vehículo con agrupación T2
Predictora	EdadVehiculo	Continua	Años de antigüedad al momento del siniestro
Predictora	Marca	Discreta (16)	Marca con agrupación T3
Predictora	Departamento	Discreta (33)	Departamento del siniestro
Predictora	NivelAutoridad	Discreta (4)	Municipal, distrital, departamental o nacional
Predictora	TipoEntidad	Discreta (7)	Secretaría de tránsito, Policía Nacional (DITRA), otras
Predictora	Mes	Continua (1–12)	Estacionalidad
Predictora	ModeloPosterior	Discreta (2)	Bandera de calidad heredada de la Etapa 3

Figura 1

Widget File con la muestra de 100.000 registros y los roles de las variables



Nota. Orange reconoce 8 predictoras, una variable objetivo con dos valores y 7 metas, tal como se definió en el archivo .tab.

Flujos de Orange, widgets y conexiones

El trabajo se organizó en tres flujos, guardados en *data/orange/* junto con sus datos. La Tabla 4 resume su contenido; los parámetros de cada widget se detallan en las secciones correspondientes a cada análisis.

Tabla 4

Flujos de Orange desarrollados

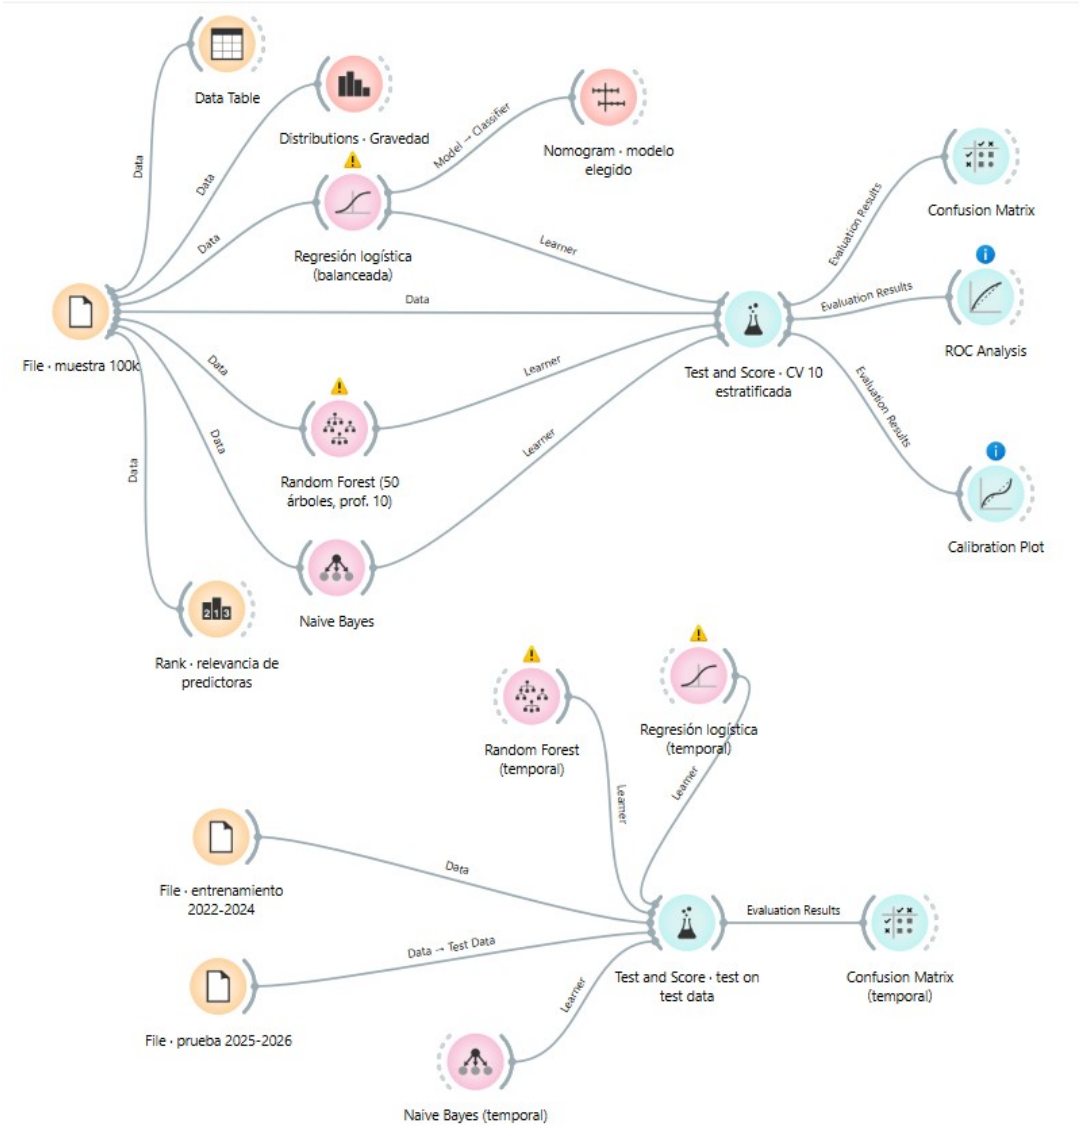
Flujo	Widgets principales	Propósito
E6_1_supervisado_gravedad.ows	File (3), Data Table, Distributions, Rank, Logistic Regression, Random Forest, Naive Bayes, Test and Score (2), Confusion Matrix (2), ROC Analysis, Calibration Plot, Nomogram	Comparar tres modelos supervisados con validación cruzada y validación temporal

Flujo	Widgets principales	Propósito
E6_2_clustering_municipios.ows	File, Data Table, k-Means, Silhouette Plot, Box Plot, Scatter Plot, PCA, Distances, Hierarchical Clustering, Save Data	Agrupar municipios por perfil vial y caracterizar los grupos
E6_3_texto_comentarios_youtube.ows	Corpus, Corpus Viewer, Statistics, Pivot Table, Preprocess Text, Bag of Words, Word Cloud, Extract Keywords, Topic Modelling, Sentiment Analysis, Box Plot, Document Embedding, Data Sampler, Distances, Hierarchical Clustering, Word Enrichment, Annotated Corpus Map	Identificar temas, términos, sentimiento y grupos en los comentarios

Las Figuras 2 y 3 muestran los lienzos del ejercicio supervisado y del agrupamiento. El lienzo del análisis de texto se presenta, junto con la explicación de cada rama, en la sección de comentarios de YouTube (Figura 43).

Figura 2

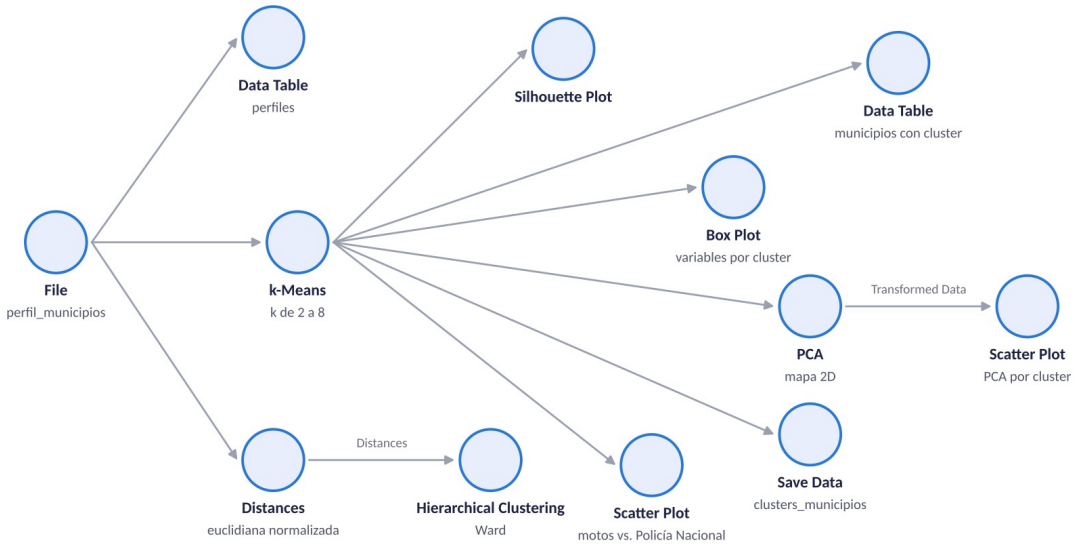
Flujo de Orange para los modelos supervisados



Nota. En la parte superior, la validación cruzada sobre la muestra de 100.000 registros; en la inferior, la validación temporal con entrenamiento 2022-2024 y prueba 2025-2026. Los avisos amarillos de los modelos balanceados son informativos.

Figura 3

Flujo de Orange para el agrupamiento de municipios



Nota. Elaboración propia a partir de los nodos y conexiones del archivo data/orange/E6_2_clustering_municipios.ows. La rama superior caracteriza los grupos de k-Means; la inferior aplica el agrupamiento jerárquico como contraste.

Modelos supervisados

Planteamiento del problema

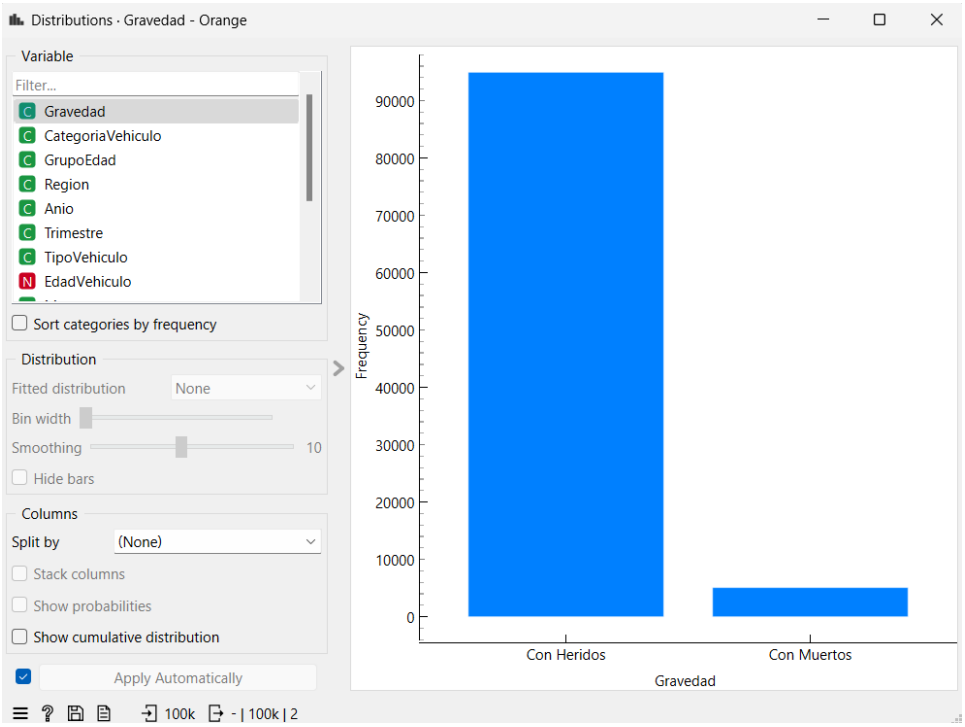
La pregunta supervisada busca anticipar si un vehículo involucrado pertenece a un siniestro con muertos. Como la variable objetivo, Gravedad, tiene dos categorías y no es una cantidad, el problema corresponde a una **clasificación binaria**. Se descartó plantearlo como regresión porque el conjunto de datos no contiene un número de víctimas por vehículo, sino la gravedad del siniestro al que pertenece.

La variable Gravedad presenta un desbalance marcado: el 94,9 % de los registros corresponde a siniestros con heridos y apenas el 5,1 % a siniestros con muertos (Figura 4). Esta proporción condiciona toda la evaluación, porque un clasificador que asignara siempre la clase

mayoritaria alcanzaría una exactitud cercana al 95 % sin identificar un solo caso fatal. Por esa razón, la comparación se apoya en métricas calculadas sobre la clase minoritaria: AUC, precisión, recall, F1 y coeficiente de correlación de Matthews (MCC).

Figura 4

Distribución de la variable objetivo Gravedad

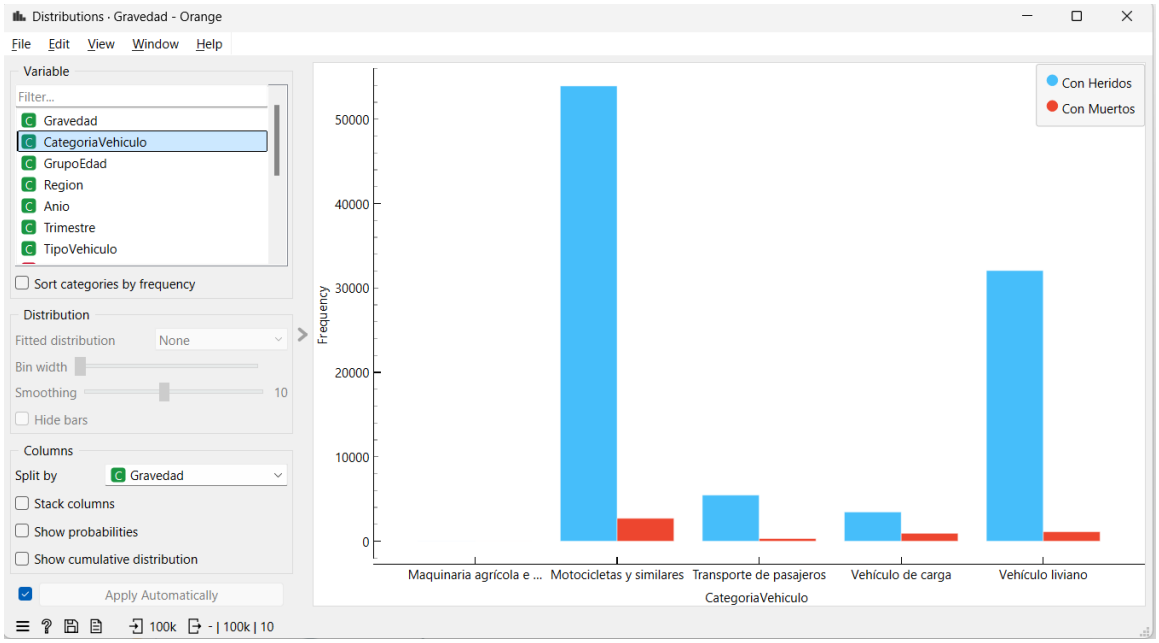


Nota. Con Heridos: 94.918 registros; Con Muertos: 5.082 registros.

La Figura 5 cruza la categoría del vehículo con la gravedad. Las motocicletas concentran el mayor volumen de registros, pero los vehículos de carga tienen proporcionalmente muchos más siniestros con muertos: su barra roja es casi un cuarto de la azul, mientras que en las motocicletas no llega al 5 %. Esta primera observación sugiere que el volumen y la letalidad responden a factores distintos.

Figura 5

Distribución de la categoría del vehículo según la gravedad



Relevancia de las variables

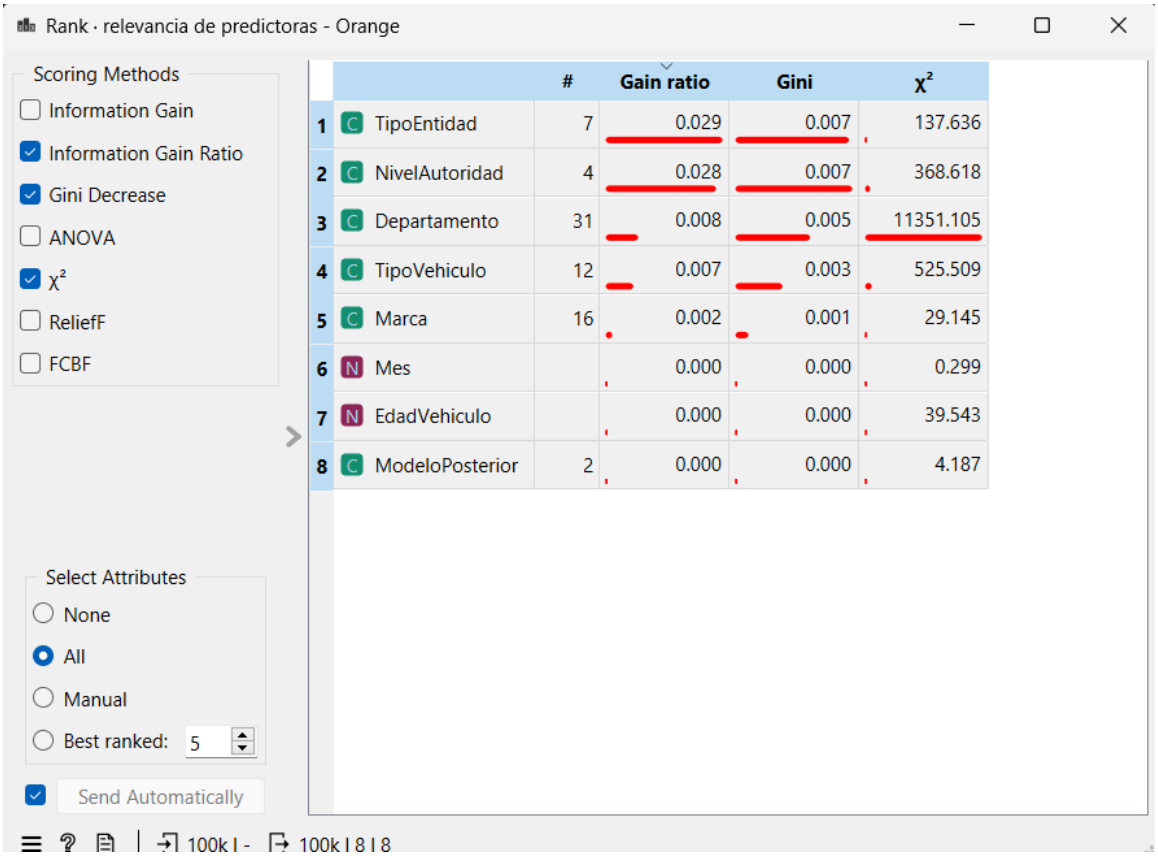
El widget Rank evalúa cada predictora por separado con tres medidas: razón de ganancia, índice de Gini y estadístico χ^2 (Figura 6). La razón de ganancia y el índice de Gini coinciden en señalar como más informativas las variables que describen a la autoridad que registra el siniestro: TipoEntidad (razón de ganancia 0,029) y NivelAutoridad (0,028). Les siguen Departamento (0,008), TipoVehiculo (0,007) y Marca (0,002), mientras que Mes, EdadVehiculo y ModeloPosterior aportan muy poca información por sí solas.

En la prueba χ^2 el orden cambia: Departamento obtiene el valor más alto (11.351), seguido de TipoVehiculo (525,5) y NivelAutoridad (368,6). Esto no contradice a las otras medidas, porque el estadístico χ^2 crece con el número de categorías y con el tamaño de la muestra, y Departamento tiene 31 categorías en 100.000 registros. Para comparar la relevancia entre variables se usan la razón de ganancia y el índice de Gini, que corrigen ese efecto. El χ^2

confirma, en cambio, que la asociación entre el departamento y la gravedad es estadísticamente significativa. Este resultado anticipa uno de los hallazgos centrales: quién atiende el siniestro, y por tanto en qué tipo de vía ocurre, dice más sobre su gravedad que el propio vehículo.

Figura 6

Widget Rank con las medidas de relevancia de las predictoras



		#	Gain ratio	Gini	χ²
1	TipoEntidad	7	0.029	0.007	137.636
2	NivelAutoridad	4	0.028	0.007	368.618
3	Departamento	31	0.008	0.005	11351.105
4	TipoVehiculo	12	0.007	0.003	525.509
5	Marca	16	0.002	0.001	29.145
6	Mes		0.000	0.000	0.299
7	EdadVehiculo		0.000	0.000	39.543
8	ModeloPosterior	2	0.000	0.000	4.187

Nota. Captura de Orange Data Mining sobre la muestra de 100.000 registros. Columnas: razón de ganancia, índice de Gini y estadístico χ^2.

Modelos y parámetros

Se implementaron tres modelos de naturaleza distinta para resolver el mismo problema: un modelo lineal probabilístico, un ensamble de árboles y un clasificador bayesiano. La Tabla 5 resume su configuración.

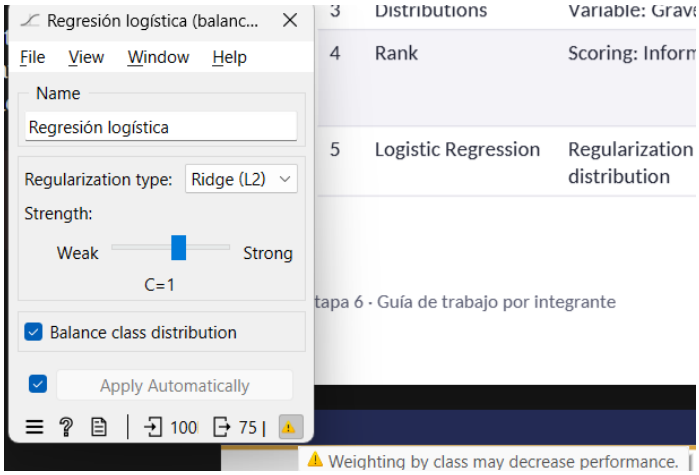
Tabla 5

Configuración de los modelos supervisados

Modelo	Parámetros	Justificación
Regresión logística	Regularización Ridge (L2), C = 1, balanceo de clases activado	Modelo interpretable; el balanceo compensa la escasez de casos fatales
Random Forest	50 árboles, entrenamiento replicable, balanceo de clases, profundidad máxima 10, no dividir subconjuntos menores de 5	Captura interacciones no lineales; sin límite de profundidad el bosque memorizaba los datos y su AUC caía a 0,77
Naive Bayes	Configuración por defecto (no admite balanceo)	Línea de comparación probabilística simple y rápida

Figura 7

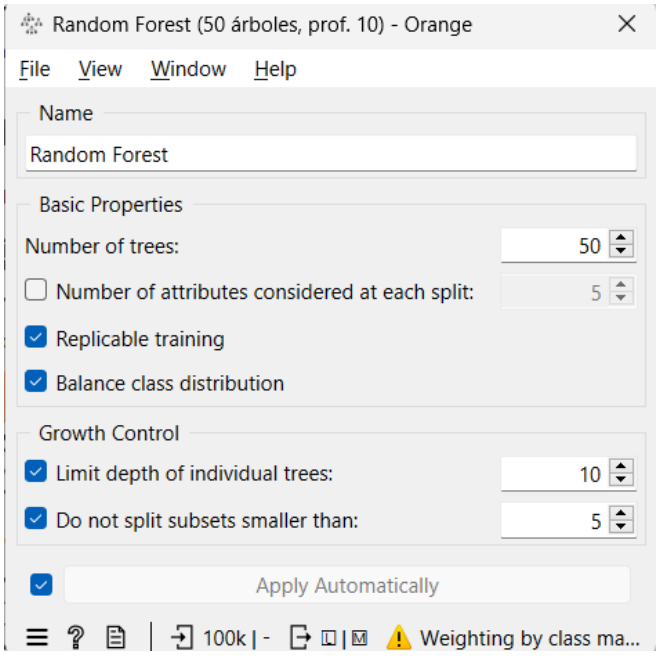
Parámetros del widget Logistic Regression



Nota. El aviso «Weighting by class may decrease performance» es informativo: el balanceo se activó deliberadamente por el desbalance de clases.

Figura 8

Parámetros del widget Random Forest



Evaluación con validación cruzada

Los tres modelos se evaluaron bajo las mismas condiciones en el widget Test and Score, con validación cruzada estratificada de 10 particiones y la clase «Con Muertos» como objetivo. Ninguna predictora contiene información que solo se conozca después del desenlace.

Figura 9

Resultados de Test and Score para la clase Con Muertos

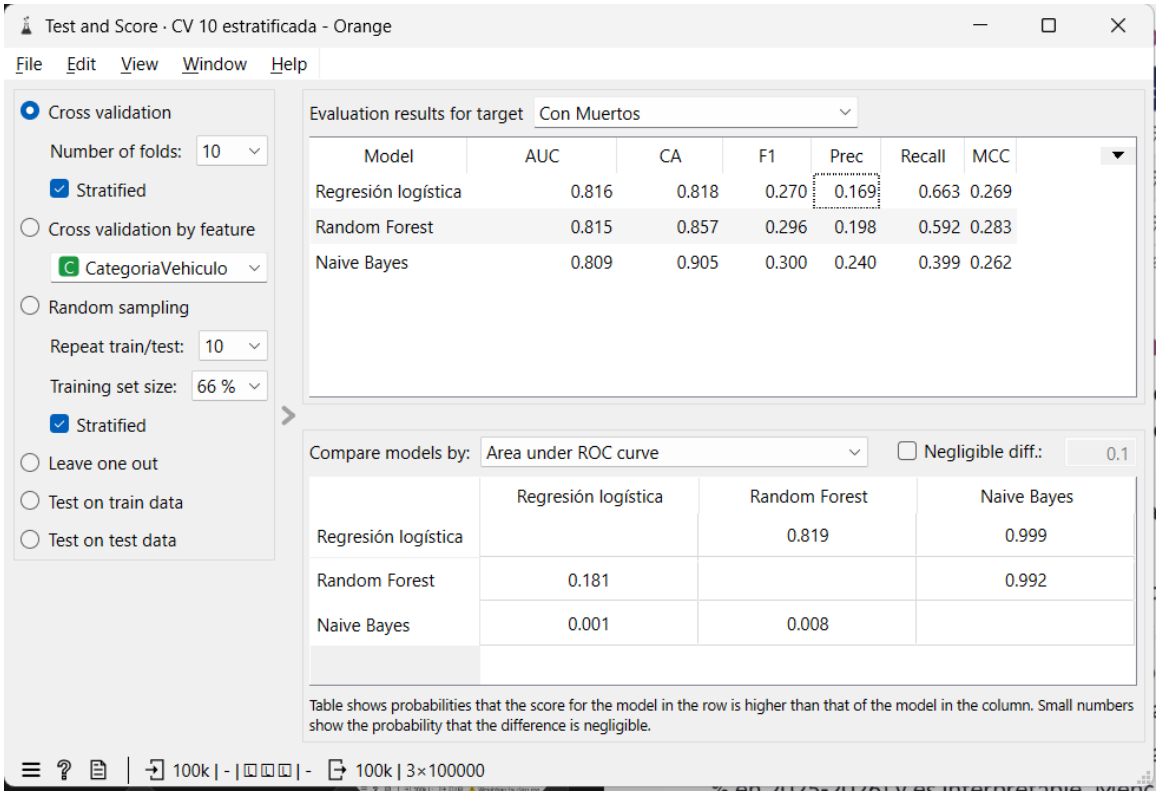


Tabla 6

Métricas de los modelos con validación cruzada de 10 particiones (clase Con Muertos)

Modelo	AUC	Exactitud	Precisión	Recall	F1	MCC
Regresión logística	0,816	81,8 %	16,9 %	66,3 %	0,270	0,269
Random Forest	0,815	85,7 %	19,8 %	59,2 %	0,296	0,283
Naive Bayes	0,809	90,5 %	24,0 %	39,9 %	0,300	0,262

Nota. Un clasificador que predijera siempre «Con Heridos» obtendría 94,9 % de exactitud y 0 % de recall.

Los tres modelos discriminan de forma parecida, con AUC entre 0,809 y 0,816, pero se comportan distinto frente a la clase fatal. La regresión logística detecta el 66,3 % de los siniestros con muertos con una precisión de 16,9 %. Random Forest detecta el 59,2 %, con una precisión de 19,8 % y el mayor MCC (0,283). Naive Bayes es el más preciso (24,0 %) y obtiene el F1 más alto (0,300), pero solo reconoce el 39,9 % de los casos fatales. Las exactitudes altas, entre 81,8

% y 90,5 %, no deben leerse como buen desempeño: reflejan sobre todo el acierto en la clase mayoritaria.

Comparación estadística entre modelos

La parte inferior de Test and Score estima la probabilidad de que un modelo supere a otro en cada métrica. En AUC, la probabilidad de que la regresión logística supere a Random Forest es de solo 0,819, de modo que la diferencia no es concluyente; frente a Naive Bayes ambos son superiores con probabilidades de 0,999 y 0,992. En recall, la superioridad de la regresión logística sobre los otros dos modelos es prácticamente segura (1,000). En F1 y MCC, en cambio, Random Forest supera a la regresión logística con probabilidades de 1,000 y 0,996. Ningún modelo domina en todas las métricas, y la elección depende del tipo de error que se considere más costoso.

Figura 10

Comparación de modelos por recall

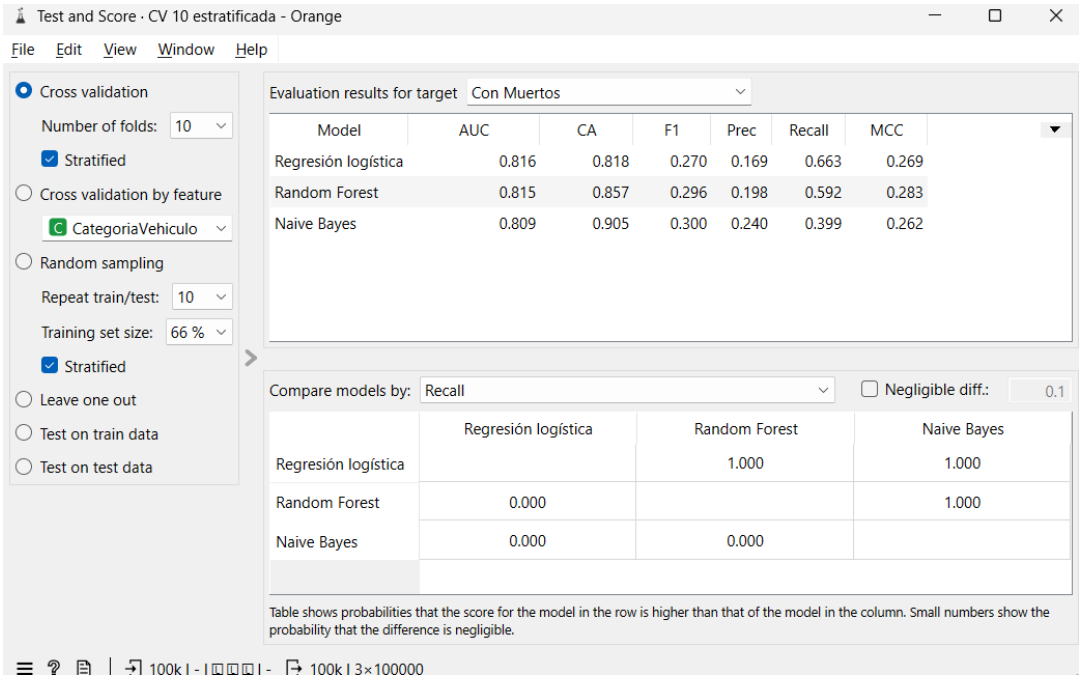


Figura 11

Comparación de modelos por F1

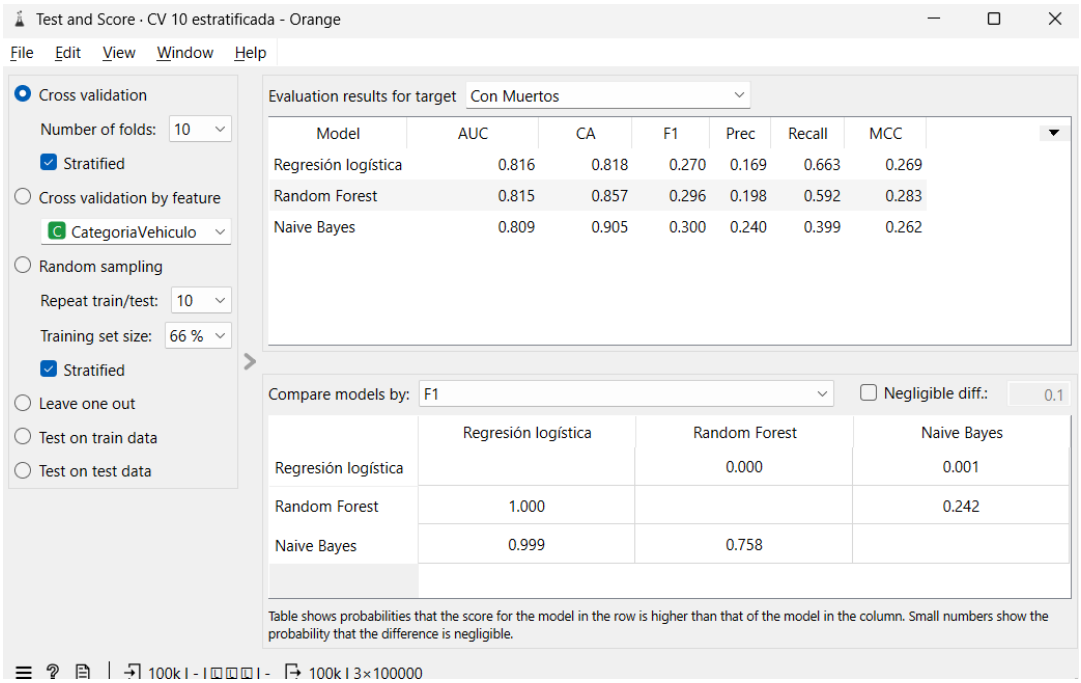
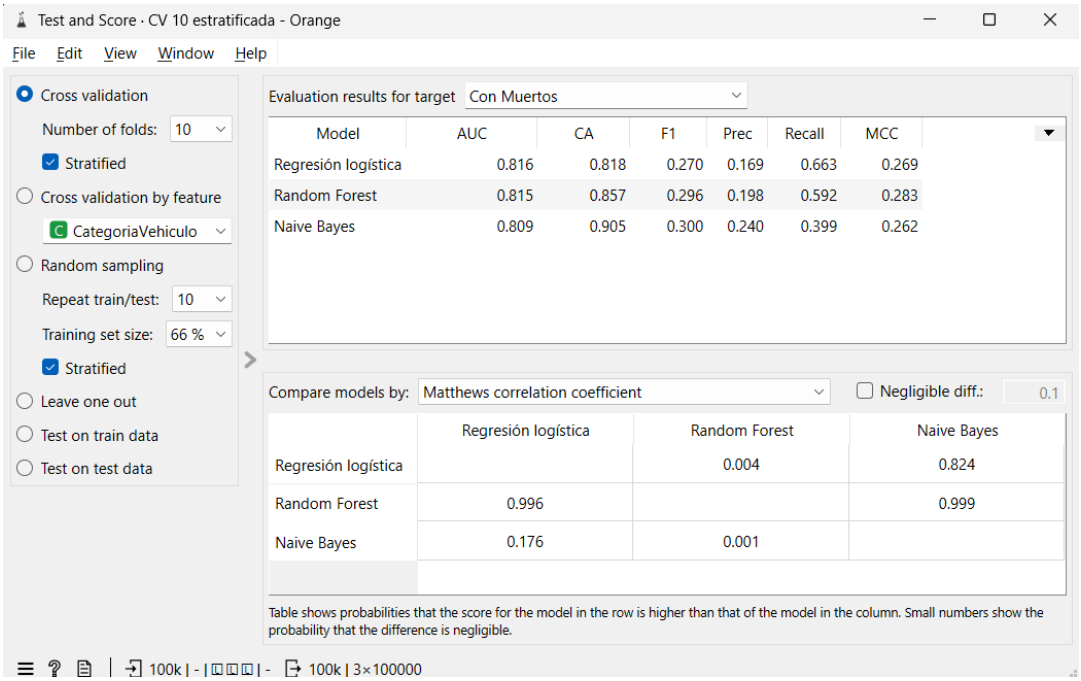


Figura 12

Comparación de modelos por MCC



Matrices de confusión

Las matrices de confusión muestran el costo de cada estrategia en número de casos. La regresión logística identifica 3.367 de los 5.082 siniestros con muertos y deja escapar 1.715, a cambio de 16.515 falsas alarmas. Random Forest identifica 3.008, pierde 2.074 y genera 12.214 falsas alarmas. Naive Bayes identifica 2.028, pierde 3.054 y genera 6.422 falsas alarmas. Frente a Random Forest, la regresión logística recupera 359 casos fatales más a costa de 4.301 alertas adicionales.

Figura 13

Matriz de confusión de la regresión logística

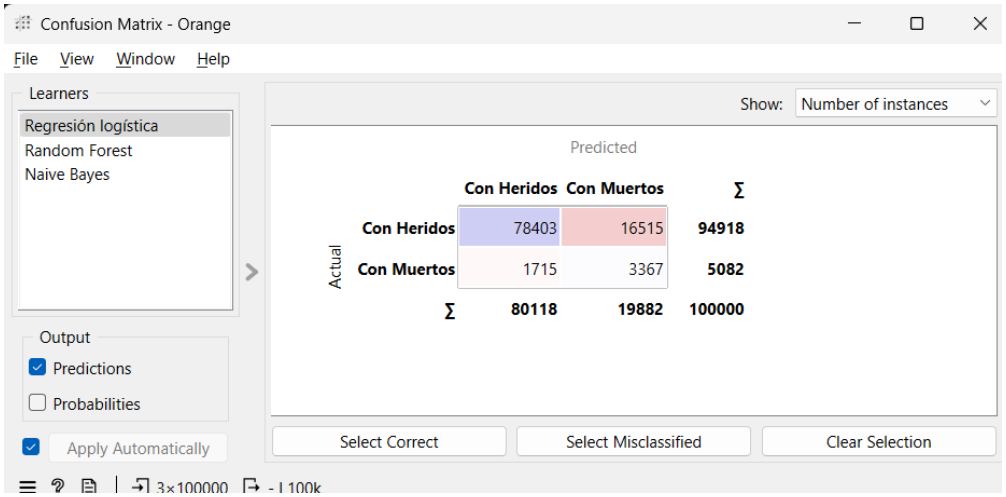


Figura 14

Matriz de confusión de Random Forest

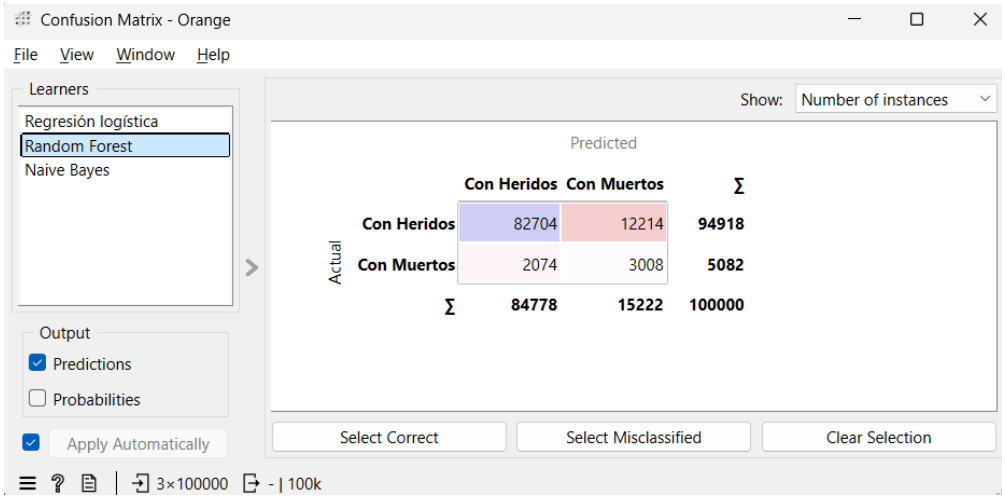
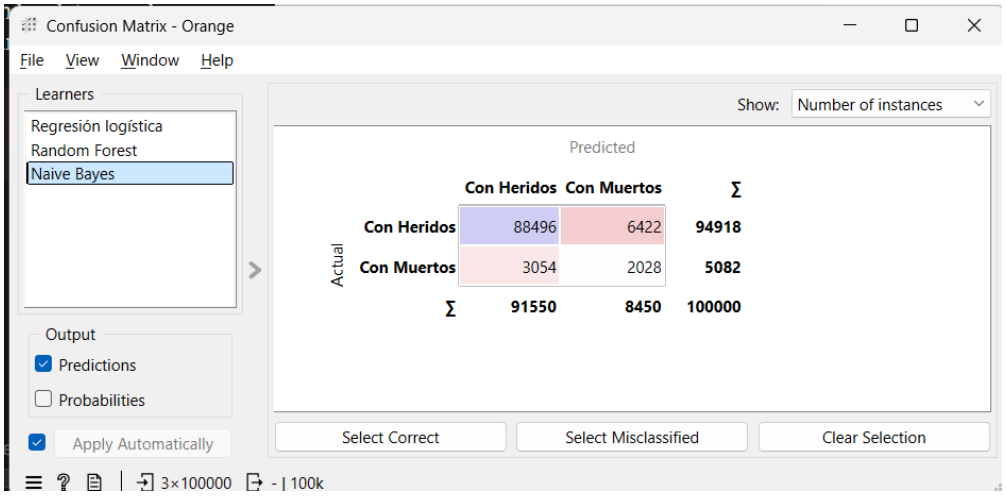


Figura 15

Matriz de confusión de Naive Bayes



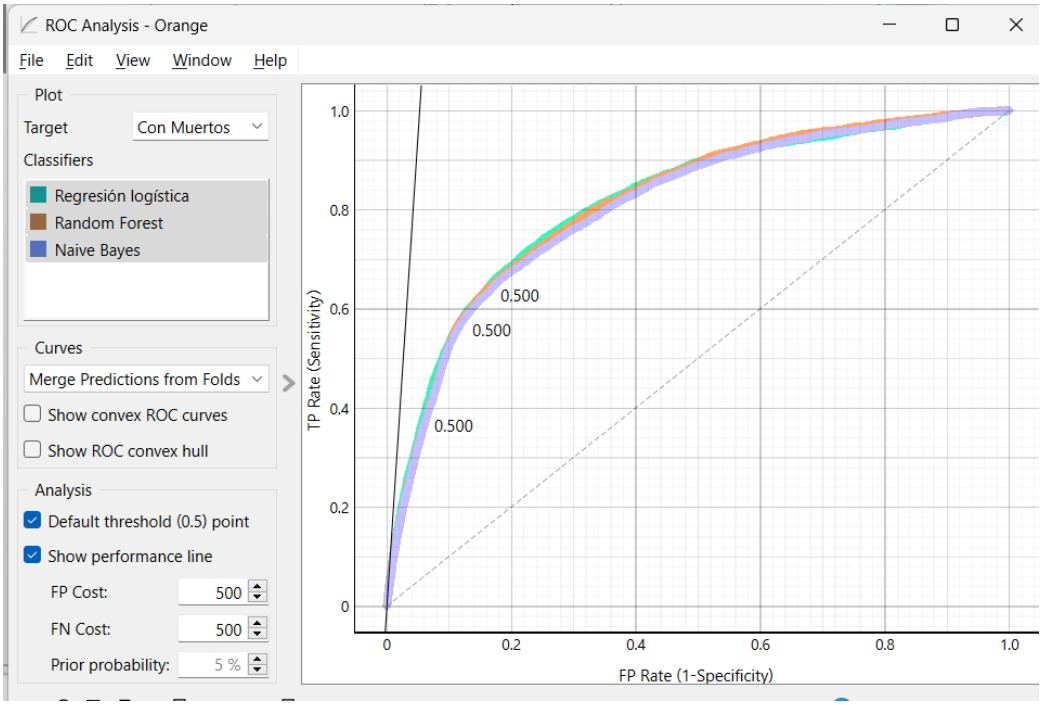
Curva ROC y calibración

Las tres curvas ROC se superponen casi por completo y se alejan con claridad de la diagonal, lo que indica que los tres modelos ordenan bien los casos según su riesgo. Los puntos marcados en el umbral de 0,5 muestran la diferencia de comportamiento: los modelos

balanceados operan con mayor sensibilidad, cercana a 0,6, mientras que Naive Bayes trabaja con una menor tasa de falsos positivos.

Figura 16

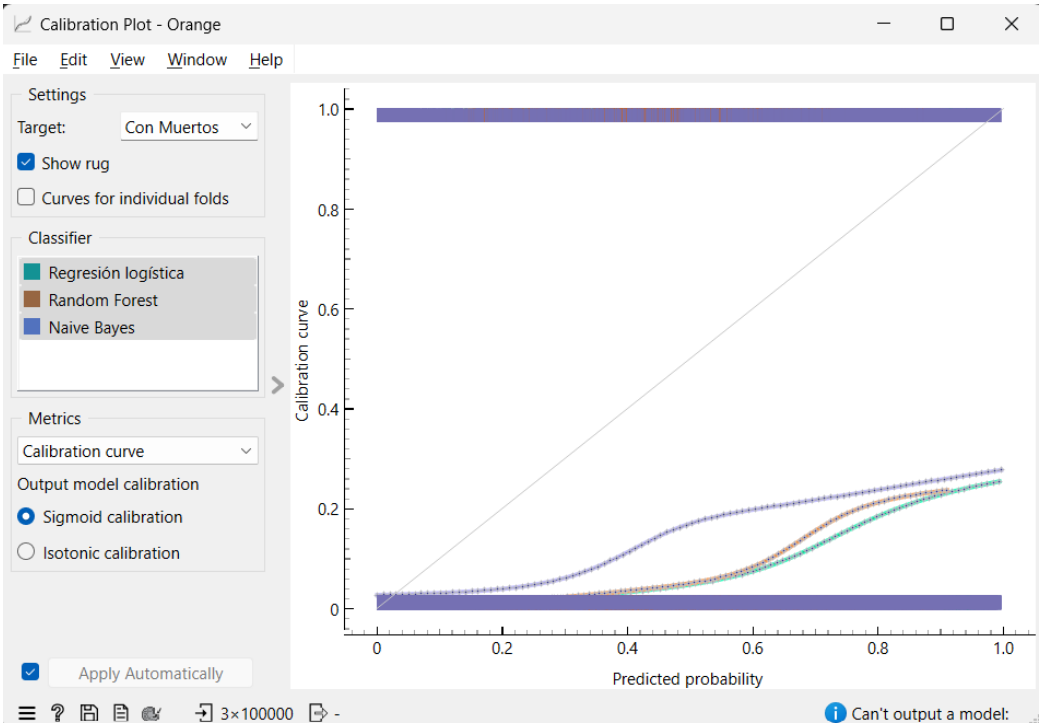
Curvas ROC para la clase Con Muertos



El gráfico de calibración muestra que, para la clase Con Muertos, las curvas quedan muy por debajo de la diagonal. Cuando los modelos balanceados asignan una probabilidad de 0,8, la frecuencia real de siniestros fatales ronda el 25 %. Es el efecto esperado del balanceo de clases: el modelo sirve para **ordenar y priorizar** casos, no para leer sus probabilidades como riesgos absolutos. Si se necesitaran probabilidades reales, habría que recalibrarlas, por ejemplo con calibración sigmoide.

Figura 17

Gráfico de calibración para la clase Con Muertos



Validación temporal

Para simular un uso real, los modelos se entrenaron con los registros de 2022 a 2024 (85.032) y se evaluaron con los de 2025 a febrero de 2026 (14.968), que no vieron durante el entrenamiento. El AUC baja ligeramente en los tres modelos, a 0,788 en la regresión logística, 0,778 en Random Forest y 0,781 en Naive Bayes. Esta caída indica que los patrones de siniestralidad cambian con el tiempo y que un modelo de este tipo debe reentrenarse periódicamente. Aun así, el orden se mantiene: la regresión logística conserva el mayor recall (76,5 %, con 907 de 1.185 siniestros fatales detectados), Random Forest el mayor MCC (0,269) y Naive Bayes la mayor precisión (23,6 %), aunque reconoce solo la mitad de los casos fatales.

Figura 18

Resultados de la validación temporal (entrenamiento 2022-2024, prueba 2025-2026)

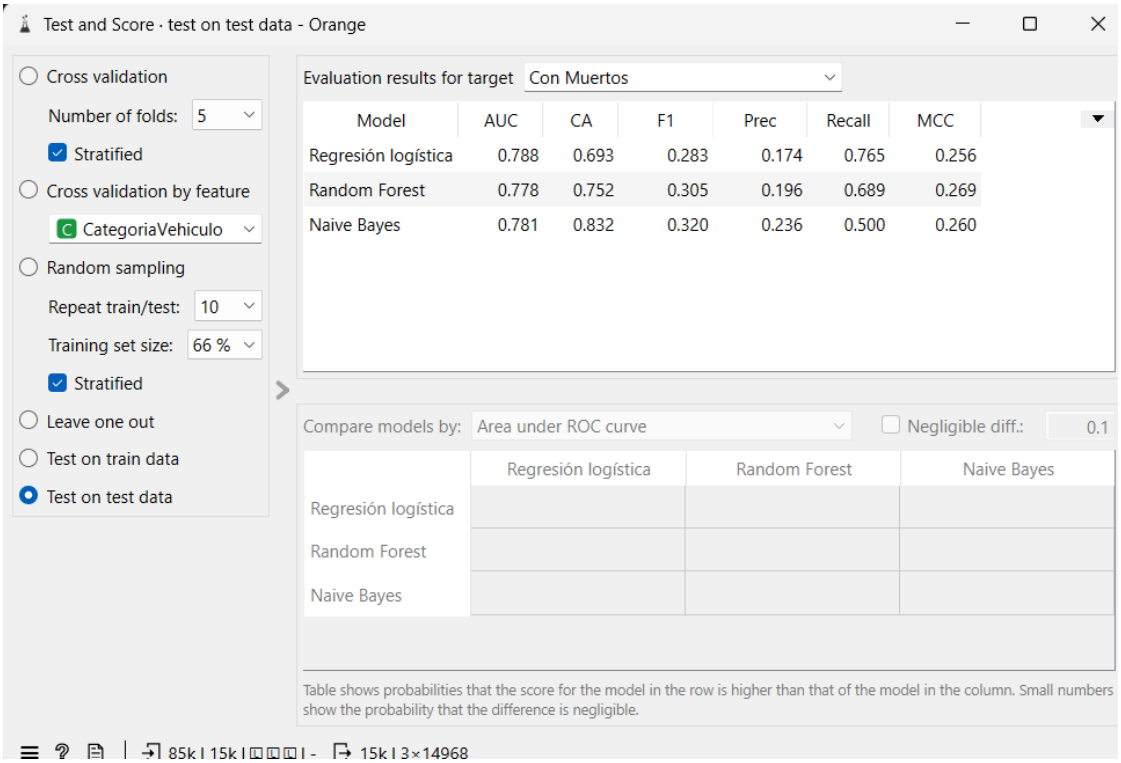


Tabla 7

Métricas de la validación temporal (clase Con Muertos)

Modelo	AUC	Exactitud	Precisión	Recall	F1	MCC	VP	FN	FP
Regresión logística	0,788	69,3 %	17,4 %	76,5 %	0,283	0,256	907	278	4.314
Random Forest	0,778	75,2 %	19,6 %	68,9 %	0,305	0,269	817	368	3.348
Naive Bayes	0,781	83,2 %	23,6 %	50,0 %	0,320	0,260	592	593	1.919

Figura 19

Matriz de confusión temporal de la regresión logística

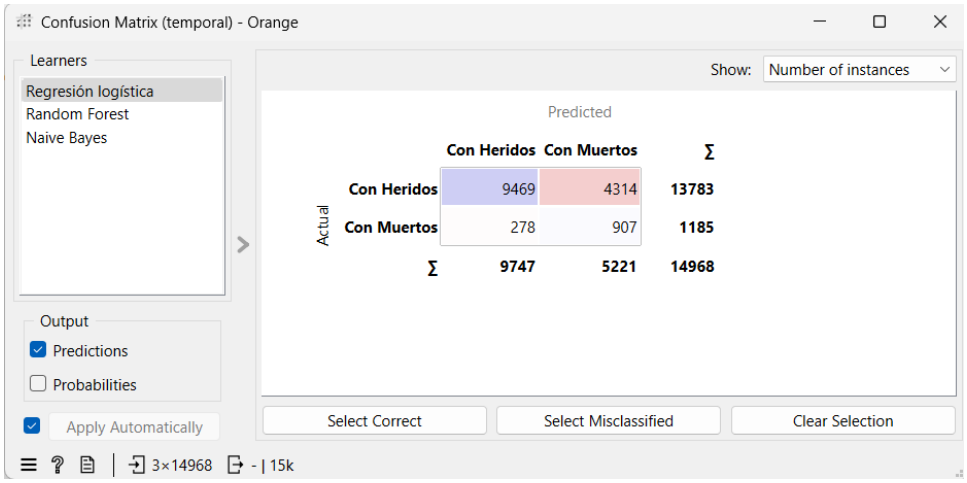


Figura 20

Matriz de confusión temporal de Random Forest

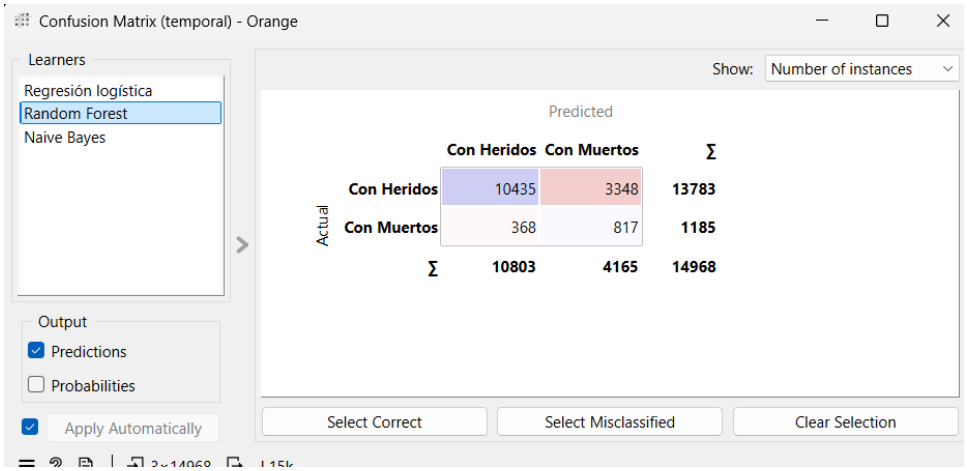
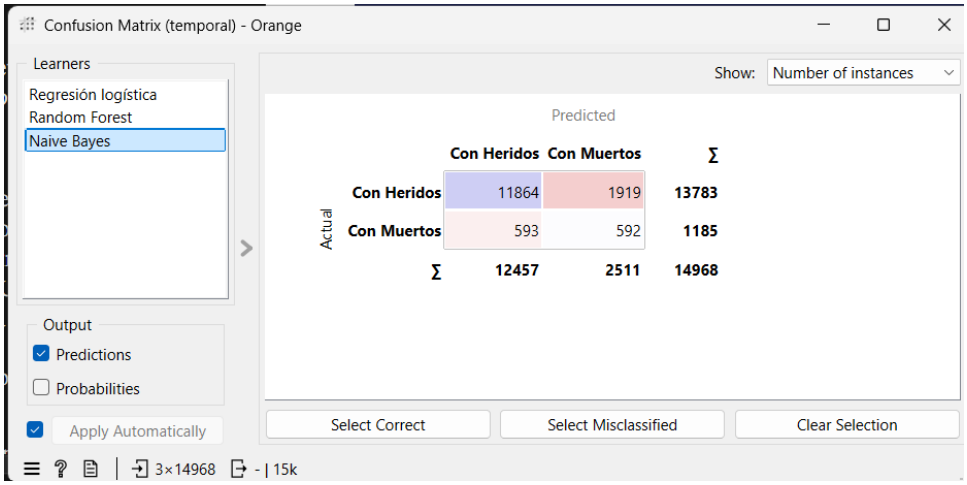


Figura 21

Matriz de confusión temporal de Naive Bayes

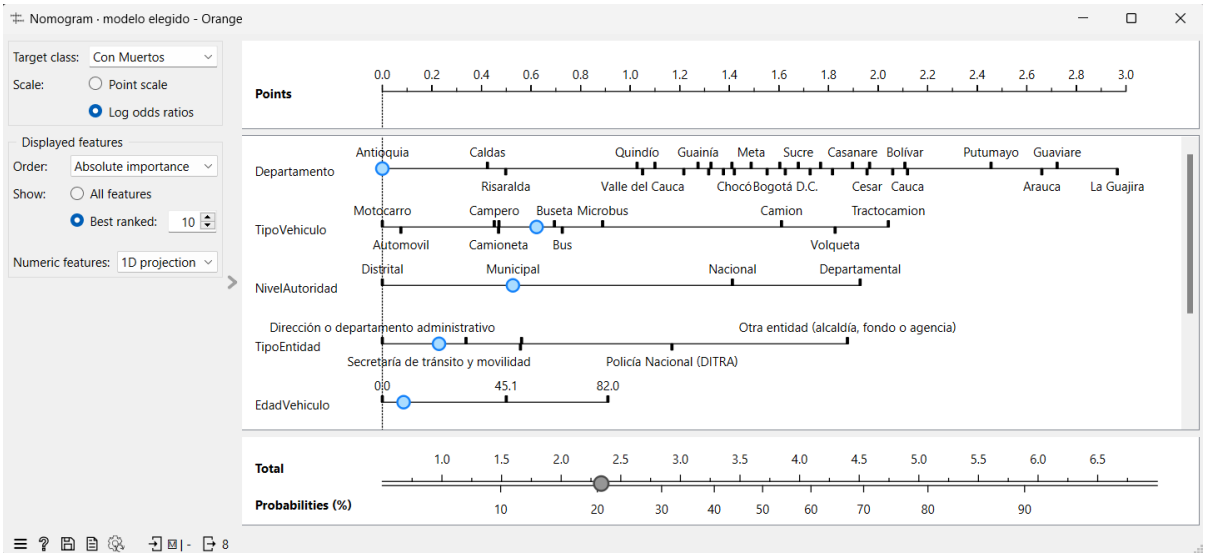


Interpretación del modelo seleccionado

El nomograma de la regresión logística muestra cuánto aporta cada valor a la probabilidad de que el siniestro sea fatal. Las variables con mayor peso son Departamento, TipoVehiculo, NivelAutoridad, TipoEntidad y EdadVehiculo. En el departamento, La Guajira, Guaviare, Arauca y Putumayo suman más puntos, mientras que Antioquia actúa como referencia de menor riesgo, seguida de Caldas y Risaralda. En el tipo de vehículo, el tractocamión, la volqueta y el camión elevan claramente la probabilidad frente al automóvil y el motocarro. Los registros de autoridades departamentales y de la Policía Nacional, propios de las vías nacionales, aumentan la probabilidad respecto a los distritales y municipales. Por último, a mayor edad del vehículo mayor es la probabilidad, aunque con un efecto menor que el de las demás variables.

Figura 22

Nomograma de la regresión logística para la clase Con Muertos



Nota. Escala en razones de momios logarítmicas; variables ordenadas por importancia absoluta.

Selección del modelo

Se selecciona la **regresión logística balanceada**. Su AUC es equivalente al de Random Forest (0,816 frente a 0,815, con una diferencia no concluyente), tiene el mayor recall tanto en validación cruzada (66,3 %) como sobre datos futuros (76,5 %) y es la única de las tres que puede explicarse mediante un nomograma. En un problema de prevención, dejar sin detectar un siniestro fatal es más grave que revisar una alerta falsa: con datos de 2025 y 2026 la regresión logística deja escapar 278 casos fatales, frente a 368 de Random Forest y 593 de Naive Bayes. Además, poder justificar por qué un caso es riesgoso es indispensable para que el resultado oriente decisiones. Random Forest queda como alternativa razonable si se prioriza el equilibrio entre precisión y recall, pues obtiene el mejor MCC.

El conocimiento que aporta el modelo es que la gravedad de un siniestro depende sobre todo del contexto vial (el territorio y la autoridad que lo atiende, que delatan si ocurrió en una vía nacional) y del tamaño del vehículo, más que de la marca, el mes o el estado del registro.

Limitaciones

- La precisión es baja (16,9 %): el modelo sirve para priorizar, no para diagnosticar casos individuales.
- El conjunto de datos no contiene variables del siniestro como hora, velocidad, clima, tipo de choque o uso de casco, que probablemente explicarían buena parte de lo que el modelo no capta.
- La gravedad describe al siniestro, no al vehículo: un vehículo registrado en un siniestro con muertos no necesariamente causó la muerte.
- El efecto negativo de Antioquia y de la autoridad distrital puede reflejar que en esas jurisdicciones se reportan más siniestros leves, no necesariamente un menor riesgo. Es una hipótesis que requiere validación.
- El desempeño disminuye en 2025 y 2026, lo que obliga a reentrenar el modelo periódicamente.

Agrupamiento de municipios

Pregunta, unidad de análisis y variables

El agrupamiento busca responder qué perfiles de municipio existen según la composición de su flota siniestrada, la antigüedad de los vehículos y la autoridad que atiende los siniestros. La unidad de análisis es el municipio. Se incluyeron los 248 municipios con al menos 50 vehículos registrados, que concentran 403.731 registros (99,3 % del total); por debajo de ese umbral los porcentajes resultan inestables.

Tabla 8

Variables activas del agrupamiento

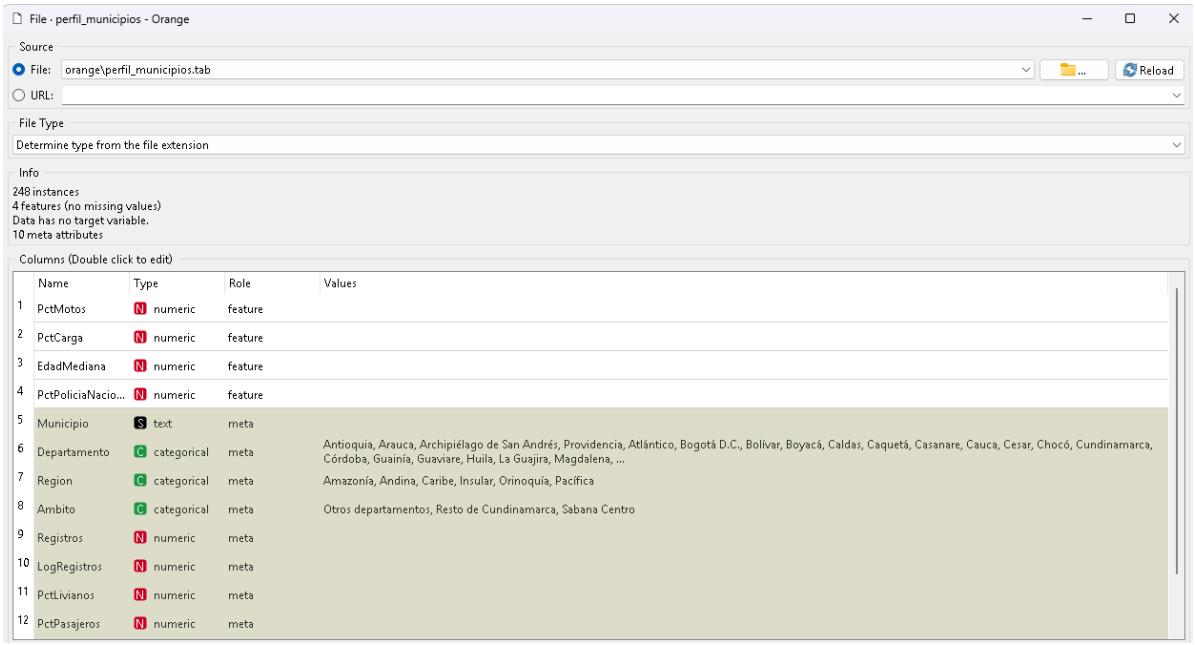
Variable	Qué mide	Por qué se eligió
PctMotos	Porcentaje de vehículos que son motocicletas	Composición modal; es la categoría más numerosa
PctCarga	Porcentaje de vehículos de carga	Presencia de tránsito de paso y logística
EdadMediana	Mediana de antigüedad de los vehículos (años)	Estado del parque automotor
PctPoliciaNacional	Porcentaje de registros hechos por la Policía Nacional	Indica siniestros en vías nacionales, fuera de la jurisdicción urbana

Se descartaron por redundancia el porcentaje de vehículos livianos (correlación de −0,61 con PctMotos), el porcentaje de vehículos con más de 15 años (0,77 con EdadMediana) y el logaritmo del número de registros, que hacía que el agrupamiento separara solo ciudades grandes de pequeñas. Con todas las variables, la silueta bajaba a valores entre 0,21 y 0,25. La variable objetivo del ejercicio supervisado no se utilizó: el porcentaje de vehículos en siniestros con muertos se conservó como meta y solo se usó después, para caracterizar los grupos.

Las variables se **estandarizaron** (media 0 y desviación 1) mediante la opción *Normalize columns* del widget k-Means. La razón es que combinan porcentajes de 0 a 100 con años de 2 a 12, y como k-Means usa la distancia euclidiana, sin estandarizar dominaría la variable de mayor varianza.

Figura 23

Widget File con el perfil de municipios

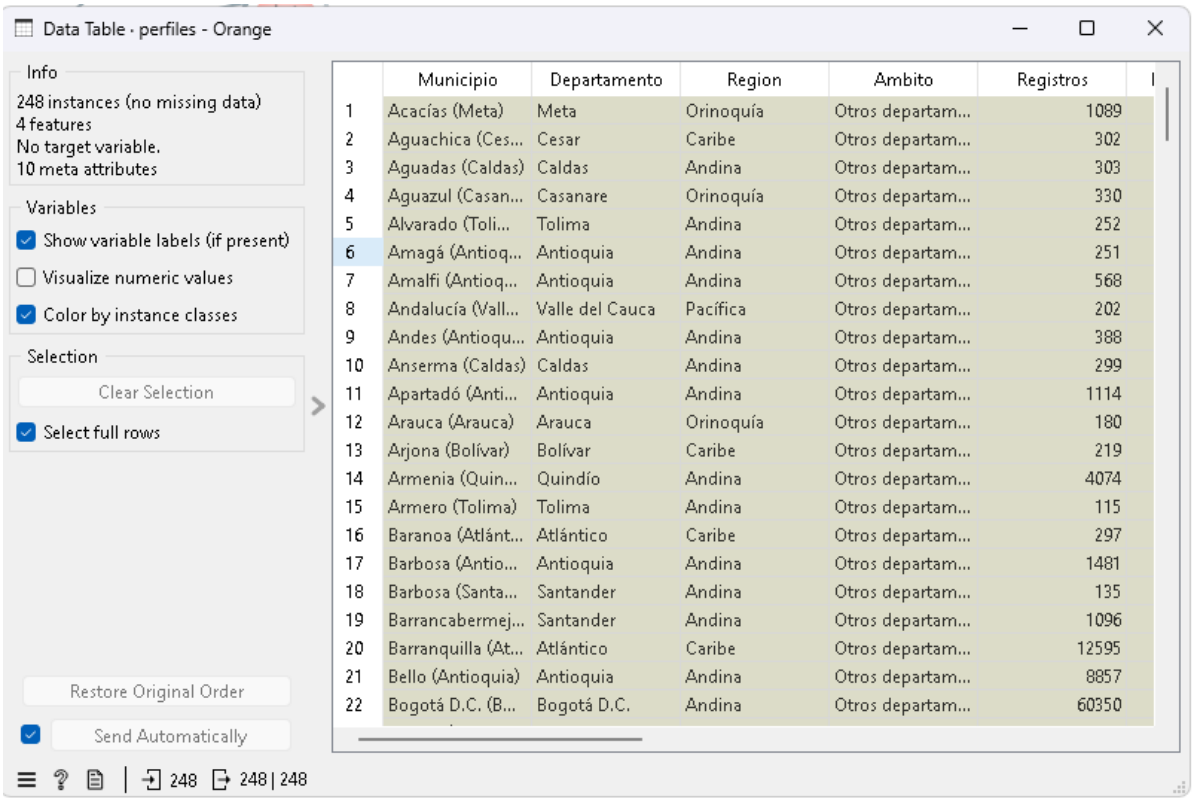


Nota. Captura de Orange Data Mining con el archivo data/orange/perfil_municipios.tab.

El archivo *perfil_municipios.tab* carga 248 municipios sin valores faltantes. Solo las cuatro variables activas (PctMotos, PctCarga, EdadMediana y PctPoliciaNacional) tienen el rol *feature*; el municipio, el departamento, la región, el ámbito, el número de registros y los demás porcentajes quedan como meta, por lo que no intervienen en el cálculo de distancias. El widget indica además que el archivo no tiene variable objetivo («Data has no target variable»): la gravedad no participa en la formación de los grupos.

Figura 24

Data Table con el perfil de los 248 municipios



	Municipio	Departamento	Region	Ambito	Registros
1	Acacías (Meta)	Meta	Orinoquía	Otros departam...	1089
2	Aguachica (Ces...	Cesar	Caribe	Otros departam...	302
3	Aguadas (Caldas)	Caldas	Andina	Otros departam...	303
4	Aguazul (Casan...	Casanare	Orinoquía	Otros departam...	330
5	Alvarado (Toli...	Tolima	Andina	Otros departam...	252
6	Amagá (Antioq...	Antioquia	Andina	Otros departam...	251
7	Amalfi (Antioq...	Antioquia	Andina	Otros departam...	568
8	Andalucía (Vall...	Valle del Cauca	Pacífica	Otros departam...	202
9	Andes (Antioqu...	Antioquia	Andina	Otros departam...	388
10	Anserma (Caldas)	Caldas	Andina	Otros departam...	299
11	Apartadó (Anti...	Antioquia	Andina	Otros departam...	1114
12	Arauca (Arauca)	Arauca	Orinoquía	Otros departam...	180
13	Arjona (Bolívar)	Bolívar	Caribe	Otros departam...	219
14	Armenia (Quin...	Quindío	Andina	Otros departam...	4074
15	Armero (Tolima)	Tolima	Andina	Otros departam...	115
16	Baranoa (Atlánt...	Atlántico	Caribe	Otros departam...	297
17	Barbosa (Antio...	Antioquia	Andina	Otros departam...	1481
18	Barbosa (Santa...	Santander	Andina	Otros departam...	135
19	Barrancabermej...	Santander	Andina	Otros departam...	1096
20	Barranquilla (At...	Atlántico	Caribe	Otros departam...	12595
21	Bello (Antioquia)	Antioquia	Andina	Otros departam...	8857
22	Bogotá D.C. (B...	Bogotá D.C.	Andina	Otros departam...	60350

La tabla permite revisar los datos antes de agrupar. Cada fila es un municipio con su departamento, región, ámbito y número de vehículos registrados; por ejemplo, Bogotá D.C. aporta 60.350 registros y Barranquilla 12.595, mientras que municipios como Armero o Barbosa (Santander) superan apenas el umbral de 50. Esta revisión confirma que la unidad de análisis es el municipio y no el vehículo, y muestra la diferencia de tamaño que justifica trabajar con porcentajes y no con conteos. El flujo completo del agrupamiento se presentó en la Figura 3.

Algoritmo y elección del número de grupos

Se aplicó k-Means con inicialización k-means++, 10 reinicios y un máximo de 300 iteraciones, probando valores de k entre 2 y 8. Como medida de calidad se usó el coeficiente de

silueta (Rousseeuw, 1987), que compara la cohesión de cada municipio con su grupo frente a su separación de los demás grupos.

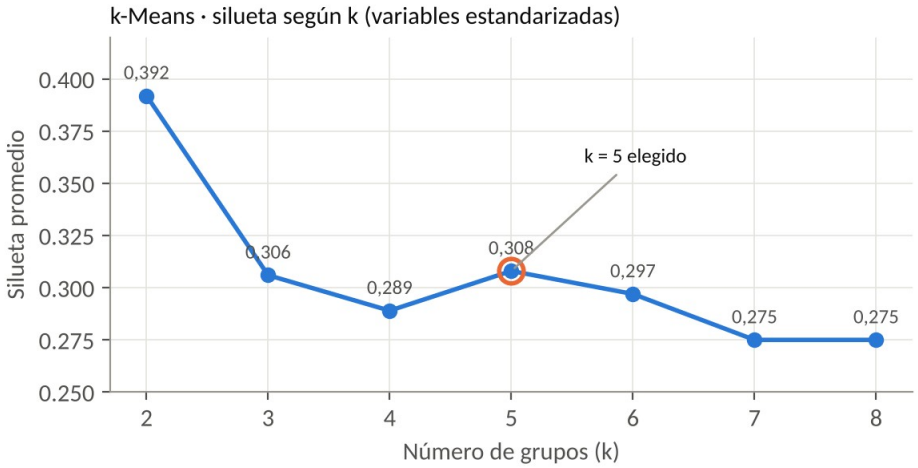
Tabla 9

Coeficiente de silueta según el número de grupos

k	2	3	4	5	6	7	8
Silueta	0,392	0,306	0,289	0,308	0,297	0,275	0,275

Figura 25

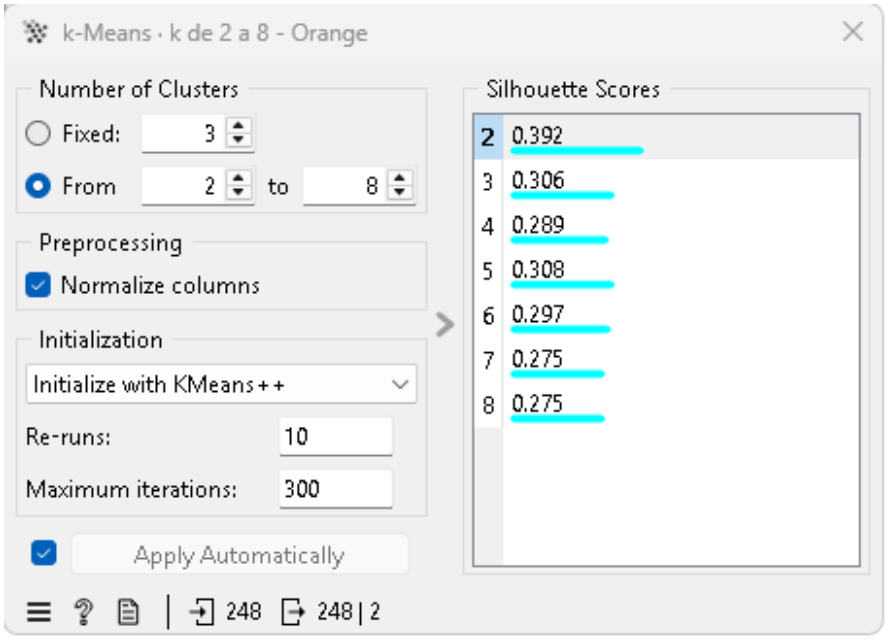
Silueta promedio según el número de grupos



Nota. Elaboración propia con los valores reportados por el widget k-Means.

Figura 26

Widget k-Means con la silueta de cada valor de k



Nota. Captura de Orange Data Mining. En la captura está seleccionada la fila k = 2, usada para el contraste; el resultado final corresponde a k = 5.

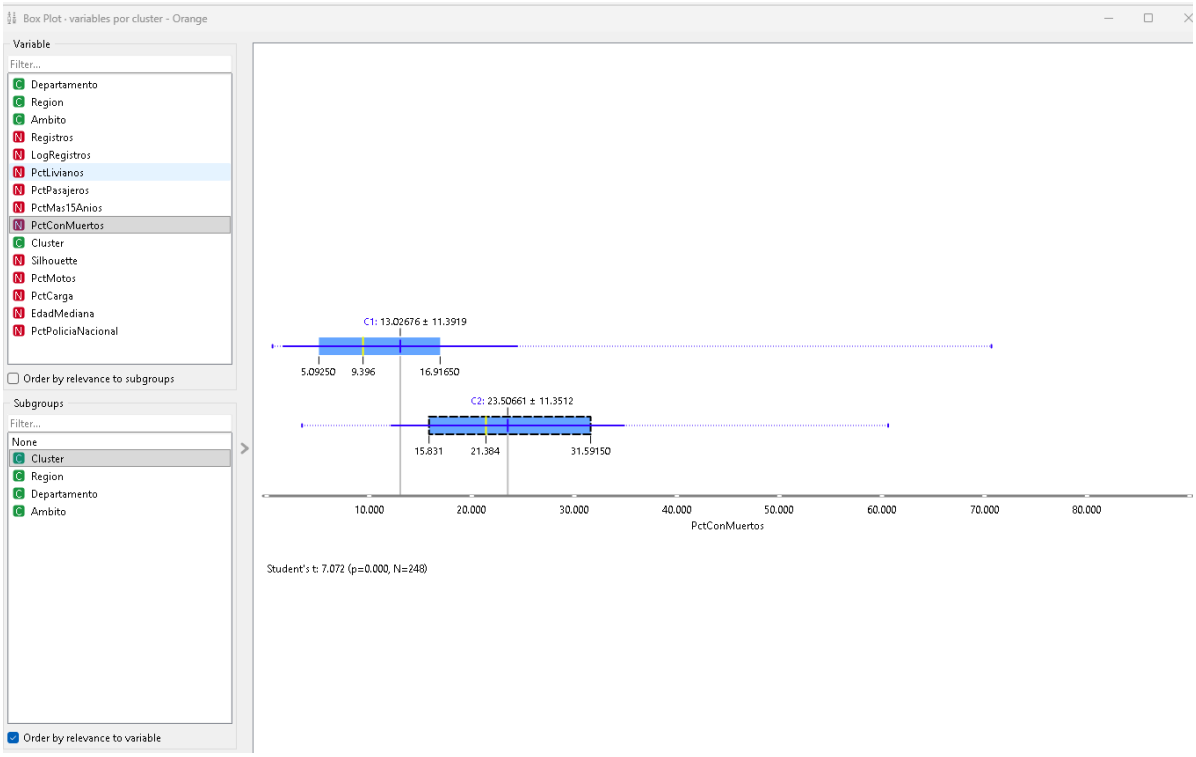
El widget evalúa k entre 2 y 8 con la opción *Normalize columns* activa, inicialización k-means++, 10 reinicios y un máximo de 300 iteraciones. Los valores de silueta que reporta son los de la Tabla 9.

Contraste con k = 2

Para respaldar la decisión de no quedarse con la silueta más alta, también se caracterizó la solución de dos grupos. Las figuras siguientes muestran que k = 2 reproduce la división entre municipios urbanos y municipios de carretera, sin distinguir perfiles dentro de cada uno.

Figura 27

Box Plot de PctConMuertos según los dos grupos de k = 2

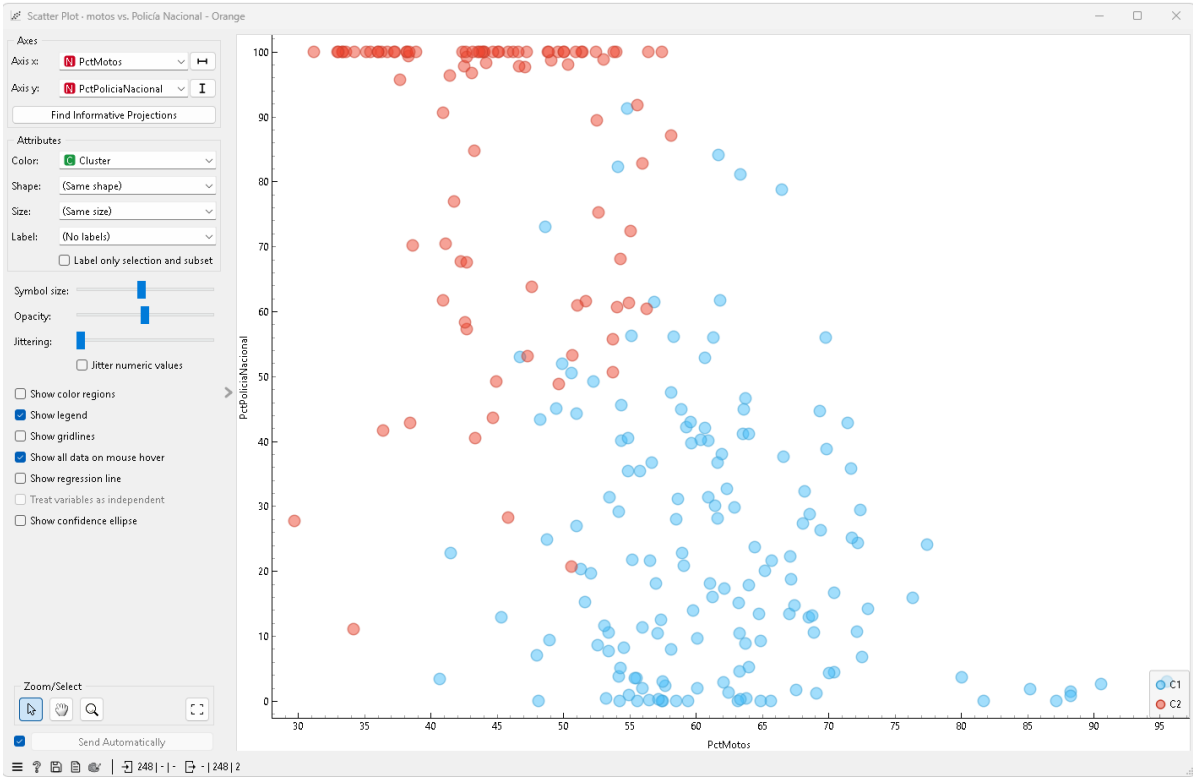


Nota. Captura de Orange Data Mining. PctConMuertos es una variable meta y se usa solo para caracterizar.

Con dos grupos, la letalidad media por municipio es de 13,0 % en C1 y de 23,5 % en C2, y la diferencia es significativa (*t* de Student = 7,07; $p < 0{,}001$; $N = 248$). Sin embargo, dentro de C1 la letalidad va de casi 0 % a más de 70 %: ese grupo mezcla centros urbanos, ciudades motorizadas y ciudades de flota envejecida, que con k = 5 quedan separados.

Figura 28

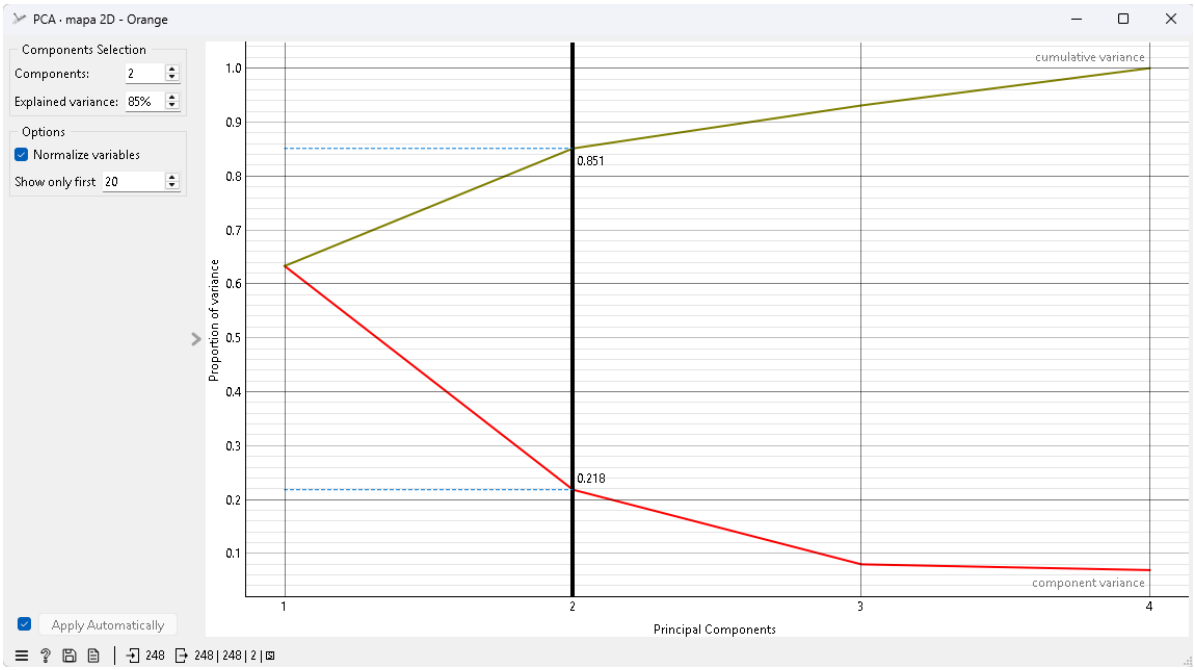
Scatter Plot de PctMotos frente a PctPoliciaNacional, coloreado según k = 2



La separación de k = 2 depende casi por completo del porcentaje de registros de la Policía Nacional. C2 (rojo) reúne los municipios donde esa autoridad registra la mayoría de los siniestros y circulan menos motos; C1 (azul), los de jurisdicción urbana, con 0 % a 60 % de registros de la Policía Nacional. Es la misma distinción entre ciudad y carretera que ya mostraba la Etapa 5.

Figura 29

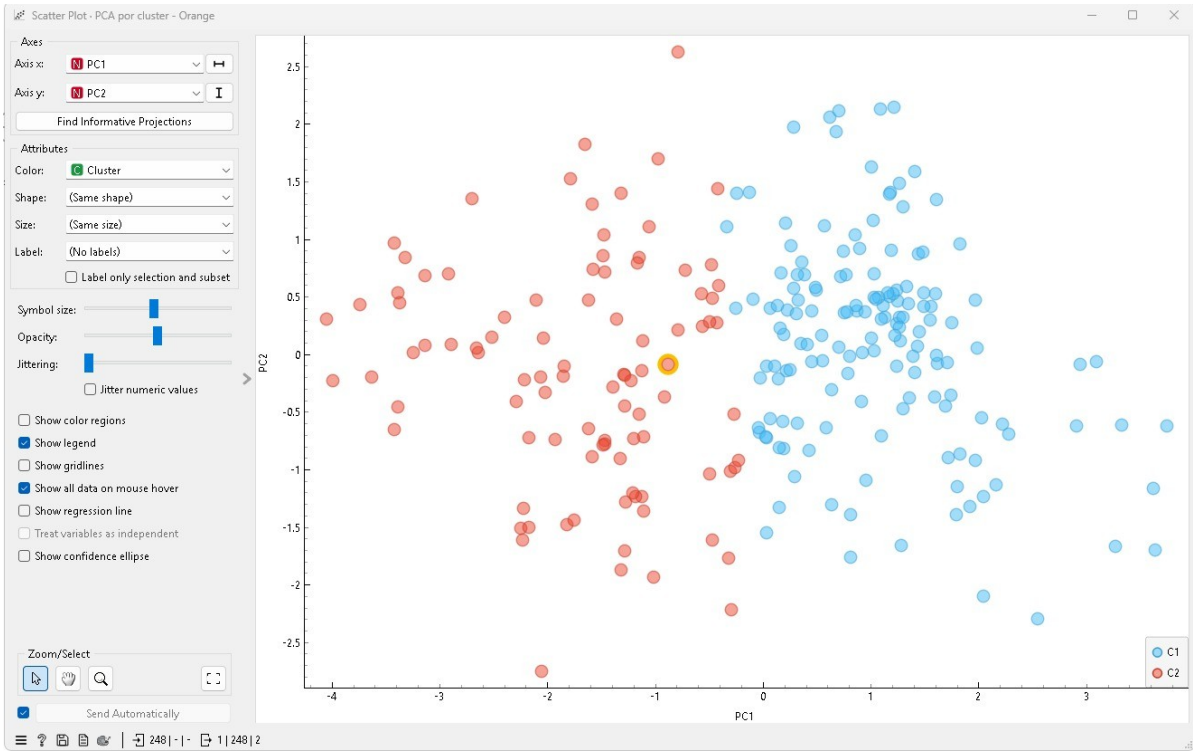
Varianza explicada por los componentes principales de las cuatro variables estandarizadas



Para visualizar los grupos en dos dimensiones se aplicó PCA sobre las mismas variables normalizadas. El primer componente explica el 63,3 % de la varianza y el segundo el 21,8 %, con un acumulado de 85,1 %, de modo que el plano de dos componentes representa bien las distancias entre municipios.

Figura 30

Municipios en el plano de los dos primeros componentes, coloreados según k = 2



En el plano PC1–PC2 los dos grupos se separan sobre todo a lo largo del primer componente y se tocan entre PC1 = −1 y PC1 = 0, donde se ubican los municipios con silueta más baja (el punto resaltado es uno de ellos). Cada nube es amplia y heterogénea, lo que confirma que dos grupos resumen demasiado la diversidad de perfiles y que k = 5 aporta más información.

Caracterización de los grupos

Tabla 10

Perfil de los cinco grupos de municipios

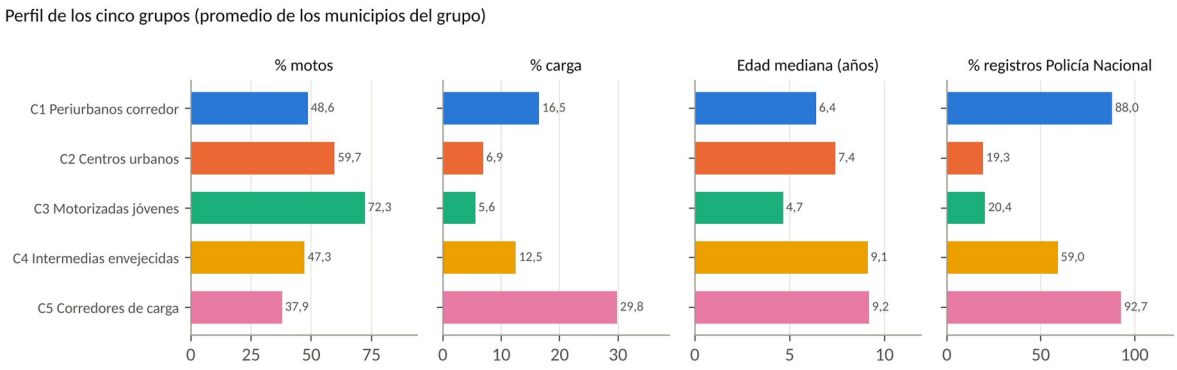
Grupo	Nombre	Mun.	Vehículos	Motos	Carga	Edad	Policía N.	Con muertos
C1	Periurbanos de corredor nacional	54	13.772	48,6 %	16,5 %	6,4	88,0 %	19,1 %

Grupo	Nombre	Mun.	Vehículos	Motos	Carga	Edad	Policía N.	Con muertos
C2	Centros urbanos con tránsito municipal	107	342.658	59,7 %	6,9 %	7,4	19,3 %	3,6 %
C3	Ciudades motorizadas de flota joven	30	34.736	72,3 %	5,6 %	4,7	20,4 %	7,0 %
C4	Ciudades intermedias de flota envejecida	32	9.033	47,3 %	12,5 %	9,1	59,1 %	16,8 %
C5	Corredores de carga	25	3.532	37,9 %	29,8 %	9,2	92,7 %	28,6 %

Nota. Los porcentajes de motos, carga y Policía Nacional son promedios de los municipios del grupo; la edad es el promedio de sus medianas. «Con muertos» es la proporción de vehículos en siniestros con muertos sobre el total del grupo, calculada después de agrupar.

Figura 31

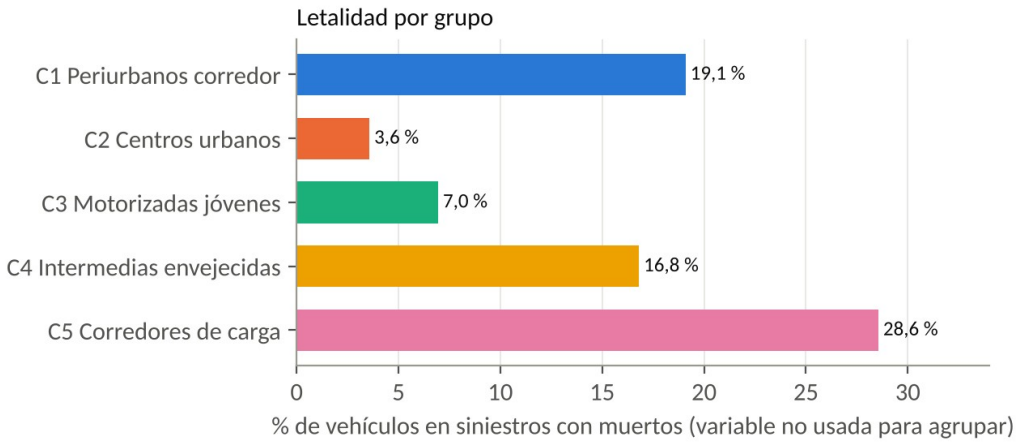
Perfil de los grupos según las variables activas



Nota. Elaboración propia a partir de los grupos obtenidos en Orange.

Figura 32

Proporción de vehículos en siniestros con muertos por grupo



Nota. Elaboración propia. Esta variable no intervino en la formación de los grupos.

- **C1 · Periurbanos de corredor nacional (54 municipios).** Municipios vecinos a grandes ciudades atravesados por vías nacionales: flota mixta, 16,5 % de carga y casi nueve de cada diez registros hechos por la Policía Nacional. Aquí se ubican Mosquera, Guarne, Cajicá, Cota, Chía y Sopó. Su letalidad es de 19,1 %.
- **C2 · Centros urbanos con tránsito municipal (107).** Bogotá, Medellín, Cali, Barranquilla y la mayoría de capitales, donde registra la secretaría de movilidad. Concentran el 85 % de los vehículos y tienen la letalidad más baja (3,6 %).
- **C3 · Ciudades motorizadas de flota joven (30).** Bello, Cartagena, Cúcuta y Montería, entre otras: siete de cada diez vehículos son motos y la mediana de antigüedad es de 4,7 años. Su letalidad es de 7,0 %.
- **C4 · Ciudades intermedias de flota envejecida (32).** Tunja, Buenaventura, Ipiales y Riohacha: la mediana de antigüedad más alta junto con C5 (9,1 años) y una mezcla de jurisdicción urbana y nacional. Letalidad de 16,8 %.

- **C5 · Corredores de carga (25).** Municipios de paso como San Diego, Ciénaga y Guaduas, con 29,8 % de vehículos de carga, flota vieja y 92,7 % de registros de la Policía Nacional. Es el grupo más letal: 28,6 %.

Para describir la similitud interna de cada grupo y su diferencia frente a los demás, la Tabla 11 expresa el centroide de cada grupo en desviaciones estándar respecto al promedio de los 248 municipios (valores *z*), junto con la silueta media de sus municipios y el grupo cuyo centroide está más cerca.

Tabla 11

Rasgos distintivos y cohesión interna de los grupos

Grupo	Motos (z)	Carga (z)	Antigüedad (z)	Policía N. (z)	Silueta media	Grupo más cercano	Rasgo que lo distingue
C5	−1,46	+2,08	+1,14	+1,25	0,436	C4	Mucha carga y casi todo registrado por la Policía Nacional
C1	−0,55	+0,54	−0,51	+1,12	0,254	C4	Vías nacionales con flota relativamente joven
C4	−0,66	+0,08	+1,10	+0,33	0,244	C1	Flota más vieja con jurisdicción mixta
C3	+1,47	−0,73	−1,54	−0,72	0,293	C2	Muchas motos y flota más joven
C2	+0,40	−0,57	+0,09	−0,75	0,329	C4	Jurisdicción urbana y poca carga

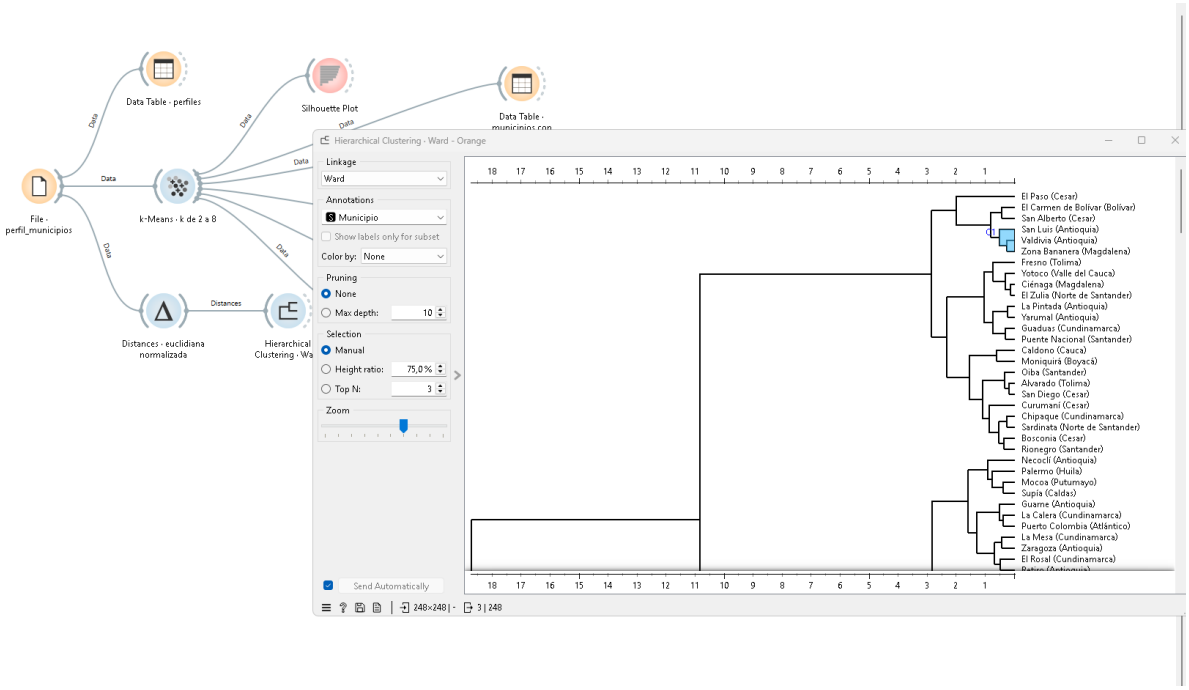
Nota. Elaboración propia a partir del archivo data/conocimiento_oculto/clusters_municipios_k5.csv exportado con Save Data. En negrita, la variable que más separa a cada grupo del promedio. Una silueta media mayor indica municipios más parecidos entre sí y mejor separados de los otros grupos.

C5 es el grupo más compacto (silueta de 0,436) y el más alejado del promedio: su rasgo dominante es la carga, más de dos desviaciones por encima de la media. C1 y C4 son los menos cohesionados (0,254 y 0,244) y se reconocen como vecinos entre sí, porque ambos combinan registros de la Policía Nacional con flotas de antigüedad intermedia; por eso algunos municipios

de frontera pueden alternar entre ellos. C3 es el opuesto de C5: muchas motos, flota joven y jurisdicción urbana.

Figura 33

Dendrograma del agrupamiento jerárquico (Ward) como contraste



Nota. Captura de Orange Data Mining. Al fondo se ve parte del lienzo, con los widgets File, k-Means, Distances, Silhouette Plot y Hierarchical Clustering conectados.

Como contraste del k-Means se aplicó un agrupamiento jerárquico con distancia euclidiana sobre las variables normalizadas y enlace Ward. La rama superior del dendrograma reúne a El Paso, San Alberto, Zona Bananera, Ciénaga, Guaduas, Moniquirá, San Diego, Bosconia y otros municipios de paso: los 24 que se ven en ella pertenecen al grupo C5 de k-Means. La rama inferior agrupa municipios como Guarne, La Calera, La Mesa, Puerto Colombia y El Rosal, que k-Means ubica en C1. Que dos algoritmos distintos coincidan indica que los perfiles no dependen del método.

Patrones ocultos y apoyo a decisiones

Sin usar la gravedad para agrupar, la proporción de vehículos en siniestros con muertos va de 3,6 % en los centros urbanos a 28,6 % en los corredores de carga. Los grupos C1 y C5, donde la Policía Nacional registra casi todo, multiplican entre cinco y ocho veces la letalidad de C2. El mismo patrón apareció en el modelo supervisado, donde la autoridad que registra fue la variable más informativa: dos métodos independientes llegan a la misma conclusión.

El hallazgo más relevante para el ámbito del proyecto es que **Sabana Centro no se comporta como Bogotá**. Cajicá, Cota, Chía y Sopó quedan en el grupo de corredor nacional, con una letalidad de 19,1 %, mientras que Zipaquirá queda con los centros urbanos. La Autopista Norte y las variantes de la región funcionan, en la práctica, como carreteras. También se observa que más motos no significa más letalidad: C3 tiene la mayor proporción de motocicletas y apenas 7,0 % de siniestros con muertos.

Estos perfiles permiten orientar decisiones diferenciadas: controles de velocidad y pesaje en los municipios de C1 y C5, incluidos los de Sabana Centro sobre la Autopista Norte; revisión técnico-mecánica en C4; y campañas dirigidas a motociclistas en C3. Entre sus limitaciones están la silueta moderada, el hecho de que los grupos se definen con registros de siniestros y no con el parque automotor, y que los porcentajes de C5 se apoyan en pocos registros por municipio (141 en promedio).

Comentarios de YouTube

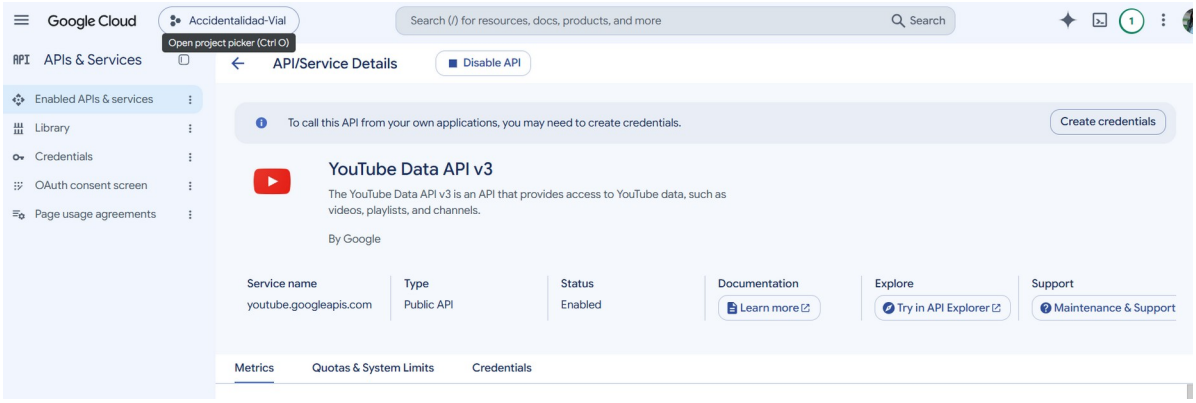
Conexión a la API de YouTube

Se creó un proyecto en Google Cloud con la cuenta de prueba gratuita del equipo, se habilitó la **YouTube Data API v3** y se generó una clave de API restringida a ese servicio. La API no tiene costo por uso: cada proyecto dispone de 10.000 unidades diarias y, al agotarlas, la

API deja de responder hasta el día siguiente sin generar cobros (Google, s. f.-a). Cada solicitud de comentarios (*commentThreads.list*) cuesta una unidad y devuelve hasta 100 hilos. La extracción se ejecutó en Google Colab con el script *scripts/extracciónc omentarios_colab.py*, que en el repositorio conserva el marcador «PEGA_AQUI_TU_CLAVE» en lugar de la clave real. Las Figuras 34 a 36 muestran la configuración.

Figura 34

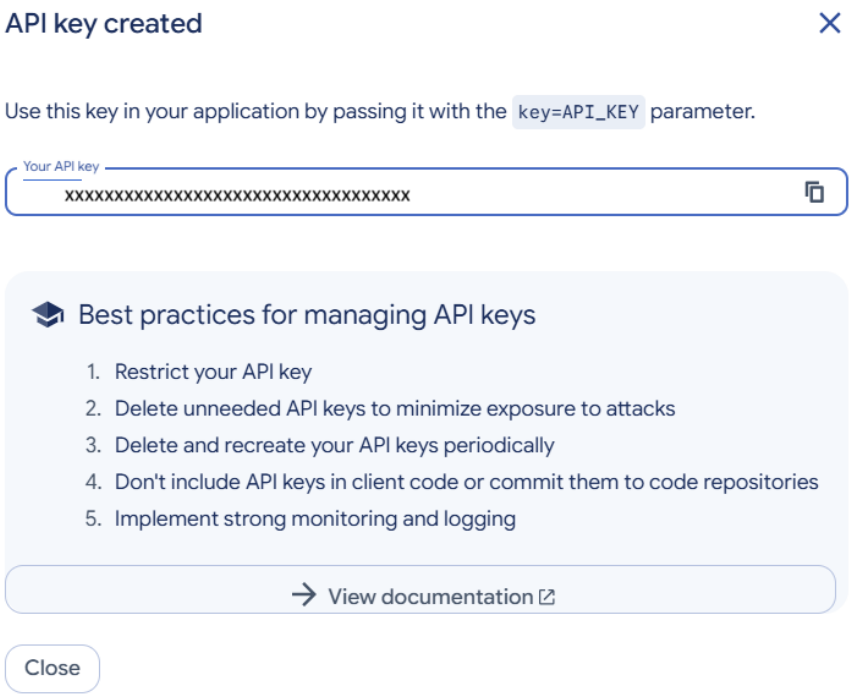
Proyecto de Google Cloud con YouTube Data API v3 habilitada



Nota. Captura de la consola de Google Cloud. El estado «Enabled» confirma que la API está activa en el proyecto.

Figura 35

Creación de la clave de API



Nota. La clave aparece oculta con caracteres «x» para no publicar la credencial. Google recomienda restringirla y no incluirla en repositorios de código.

Figura 36

Configuración del script de extracción en Google Colab



```
[1]
✓ 1s
# ============================================================
import hashlib, time
import requests
import pandas as pd
from datetime import datetime
from google.colab import files

API_KEY = "PEGA_AQUI_TU_CLAVE"
MAX_POR_VIDEO = 1500
LIMITE_UNIDADES = 2000

VIDEOS = [
    ("IIyUWDp8pRE", "carga"), ("S5wDtAQIiHI", "carga"),
    ("3X6taeC-x7U", "carga"), ("uOJRwnAtSjg", "carga"),
    ("41cyBLOZeMI", "motos"), ("1jY69g9j0bI", "motos"), ("sEgXFtSipkg", "motos"),
    ("IFh9zbJY2oM", "motos"), ("Ju_42thsgFw", "motos"), ("F1JlN_dRDKs", "motos"),
    ("JQJJjahhZ2A", "parque_control"), ("Qp8ZlD4O0Dk", "parque_control"),
    ("aR-mgVmUSys", "parque_control"), ("J7KUrioAWgU", "parque_control"),
    ("a1PRXdJSptA", "parque_control"),
    ("ZssODcZxkOw", "pasajeros"), ("Rzzrh-hZ_h8", "pasajeros"),
    ("ceLoxBwSeX8", "justicia_conducta"), ("9fn2NfMpsUI", "justicia_conducta"),
    ("W_tMFY1AhxQ", "sabana_corredores"), ("QM1GijSo2Wg", "sabana_corredores"),
]

def anonimizar(snippet):
    autor = (snippet.get("authorChannelId") or {}).get("value", "")
    return hashlib.sha256(("etapa6" + autor).encode()).hexdigest()[:16] if autor else ""

comentarios, resumen = [], []
unidades = 0
```

Nota. Se observan la clave reemplazada por el marcador PEGA_AQUI_TU_CLAVE, el límite de 1.500 hilos por video, el tope de 2.000 unidades, la lista de videos con su eje y la función que anonimiza al autor con SHA-256.

Criterios de búsqueda y selección de videos

La selección respondió a un propósito explícito: contrastar los hallazgos de los datos con la percepción ciudadana. Por eso los videos se organizaron en seis ejes, cada uno vinculado a un resultado previo: carga (el accidente de La Línea de enero de 2022), motocicletas, parque automotor y control, transporte de pasajeros, conducta y justicia, y corredores de Sabana Centro. Se revisaron cerca de 280 videos y se midió su número de comentarios antes de elegirlos. Los criterios fueron: contexto colombiano, tema de siniestralidad o normas de tránsito, comentarios habilitados y, salvo en el eje de Sabana Centro, al menos unos 400 comentarios reportados por

YouTube al momento de la selección (el número descargado puede ser algo menor, porque la API no entrega comentarios retenidos o eliminados).

Una prueba previa justificó estos criterios. El video de EL TIEMPO que mostraba el momento previo al accidente de La Línea reunía 809 comentarios, pero 231 eran quejas porque el título prometía imágenes del choque, 187 tenían menos de cuatro palabras y solo unos 95 discutían causas o soluciones. El mismo accidente, cubierto por otros cuatro videos centrados en sus causas, ofreció material mucho más útil.

Tabla 12

Videos seleccionados y comentarios extraídos (extracción del 10 de noviembre de 2026)

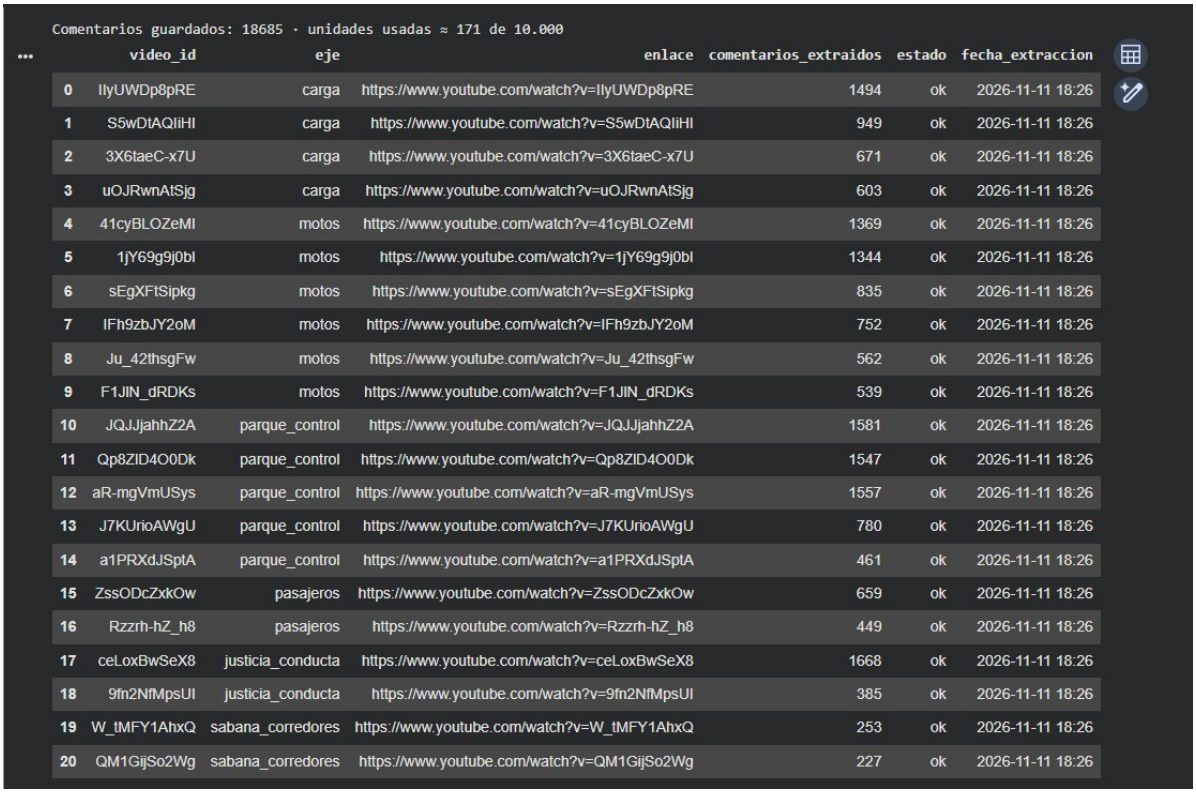
Eje	Video	Comentarios
Carga (La Línea)	Tractomula sin control en La Línea (youtube.com/watch?v=IIyUWDp8pRE)	1.494
Carga (La Línea)	Bombero que atendió el accidente de La Línea (youtube.com/watch?v=S5wDtAQIiHI)	949
Carga (La Línea)	Tractomula lanzó carro familiar contra un túnel en La Línea (youtube.com/watch?v=3X6taeC-x7U)	671
Carga (La Línea)	Habla el conductor de la tractomula de La Línea (youtube.com/watch?v=uOJRwnAtSjg)	603
Motocicletas	Joven muere haciendo piruetas en moto en Medellín (youtube.com/watch?v=41cyBLOZeMI)	1.369
Motocicletas	Motociclistas invaden carril de TransMilenio (youtube.com/watch?v=1jY69g9j0bI)	1.344
Motocicletas	Séptimo Día: menores sin casco en moto (youtube.com/watch?v=sEgXFtSipkg)	835
Motocicletas	Séptimo Día: mototaxi por aplicación y víctimas (youtube.com/watch?v=IFh9zbJY2oM)	752
Motocicletas	Séptimo Día: rodada de motociclistas termina en tragedia (youtube.com/watch?v=Ju_42thsgFw)	562
Motocicletas	Por qué hay tantas muertes en moto (youtube.com/watch?v=F1JlN_dRDKs)	539
Parque y control	Revisión técnico-mecánica: lo que hay que saber (youtube.com/watch?v=JQJJjahhZ2A)	1.581
Parque y control	Multas por SOAT y técnico-mecánica 2025 (youtube.com/watch?v=Qp8ZlD4O0Dk)	1.547
Parque y control	Cambios en las licencias de conducción (youtube.com/watch?v=aR-mgVmUSys)	1.557
Parque y control	Pico y placa para motos (youtube.com/watch?v=J7KUrioAWgU)	780

Eje	Video	Comentarios
Parque y control	Séptimo Día: vacío legal de vehículos eléctricos (youtube.com/watch?v=a1PRXdJSptA)	461
Pasajeros	Accidente de bus de excursión en Antioquia (youtube.com/watch?v=ZssODcZxkOw)	659
Pasajeros	Qué se sabe del bus en Antioquia con 17 muertos (youtube.com/watch?v=Rzzrh-hZ_h8)	449
Conducta y justicia	Séptimo Día: ¿accidente u homicidio? joven atropellado en Ocaña (youtube.com/watch?v=ceLoxBwSeX8)	1.668
Conducta y justicia	Séptimo Día: conductores borrachos provocan tragedias (youtube.com/watch?v=9fn2NfMpsUI)	385
Sabana Centro	Accidente en la vía Bogotá–Tunja con tres muertos (youtube.com/watch?v=W_tMFY1AhxQ)	253
Sabana Centro	Explosión en la vía Zipaquirá–Ubaté (youtube.com/watch?v=QM1GijSo2Wg)	227
	Total (21 videos)	18.685

Nota. Los videos se usan como fuente de datos y se identifican por su enlace. Los conteos incluyen comentarios principales y hasta cinco respuestas por hilo. En una primera ejecución el video S5wDtAQIiHI se interrumpió por un error del servidor de la API tras 406 comentarios; al repetir la extracción se obtuvo completo.

Figura 37

Resumen de la extracción por video generado en Google Colab



Comentarios guardados: 18685 · unidades usadas ≈ 171 de 10.000

	video_id	eje	enlace	comentarios_extraidos	estado	fecha_extraccion
0	IlyUWDp8pRE	carga	https://www.youtube.com/watch?v=IlyUWDp8pRE	1494	ok	2026-11-11 18:26
1	S5wDtAQIiHI	carga	https://www.youtube.com/watch?v=S5wDtAQIiHI	949	ok	2026-11-11 18:26
2	3X6taeC-x7U	carga	https://www.youtube.com/watch?v=3X6taeC-x7U	671	ok	2026-11-11 18:26
3	uOJRwnAtSjg	carga	https://www.youtube.com/watch?v=uOJRwnAtSjg	603	ok	2026-11-11 18:26
4	41cyBLOZeMI	motos	https://www.youtube.com/watch?v=41cyBLOZeMI	1369	ok	2026-11-11 18:26
5	1jY69g9j0bI	motos	https://www.youtube.com/watch?v=1jY69g9j0bI	1344	ok	2026-11-11 18:26
6	sEgXFtSipkg	motos	https://www.youtube.com/watch?v=sEgXFtSipkg	835	ok	2026-11-11 18:26
7	IFh9zbJY2oM	motos	https://www.youtube.com/watch?v=IFh9zbJY2oM	752	ok	2026-11-11 18:26
8	Ju_42thsgFw	motos	https://www.youtube.com/watch?v=Ju_42thsgFw	562	ok	2026-11-11 18:26
9	F1JIN_dRDKs	motos	https://www.youtube.com/watch?v=F1JIN_dRDKs	539	ok	2026-11-11 18:26
10	JQJJjahhZ2A	parque_control	https://www.youtube.com/watch?v=JQJJjahhZ2A	1581	ok	2026-11-11 18:26
11	Qp8ZID4O0Dk	parque_control	https://www.youtube.com/watch?v=Qp8ZID4O0Dk	1547	ok	2026-11-11 18:26
12	aR-mgVmUSys	parque_control	https://www.youtube.com/watch?v=aR-mgVmUSys	1557	ok	2026-11-11 18:26
13	J7KUrioAWgU	parque_control	https://www.youtube.com/watch?v=J7KUrioAWgU	780	ok	2026-11-11 18:26
14	a1PRXdJSptA	parque_control	https://www.youtube.com/watch?v=a1PRXdJSptA	461	ok	2026-11-11 18:26
15	ZssODcZxkOw	pasajeros	https://www.youtube.com/watch?v=ZssODcZxkOw	659	ok	2026-11-11 18:26
16	Rzzrh-hZ_h8	pasajeros	https://www.youtube.com/watch?v=Rzzrh-hZ_h8	449	ok	2026-11-11 18:26
17	ceLoxBwSeX8	justicia_conducta	https://www.youtube.com/watch?v=ceLoxBwSeX8	1668	ok	2026-11-11 18:26
18	9fn2NfMpsUI	justicia_conducta	https://www.youtube.com/watch?v=9fn2NfMpsUI	385	ok	2026-11-11 18:26
19	W_tMFY1AhxQ	sabana_corredores	https://www.youtube.com/watch?v=W_tMFY1AhxQ	253	ok	2026-11-11 18:26
20	QM1GijSo2Wg	sabana_corredores	https://www.youtube.com/watch?v=QM1GijSo2Wg	227	ok	2026-11-11 18:26

Nota. La primera línea indica 18.685 comentarios guardados y 171 de las 10.000 unidades diarias consumidas. Cada fila muestra el identificador del video, su eje, el enlace, los comentarios extraídos, el estado y la fecha de extracción.

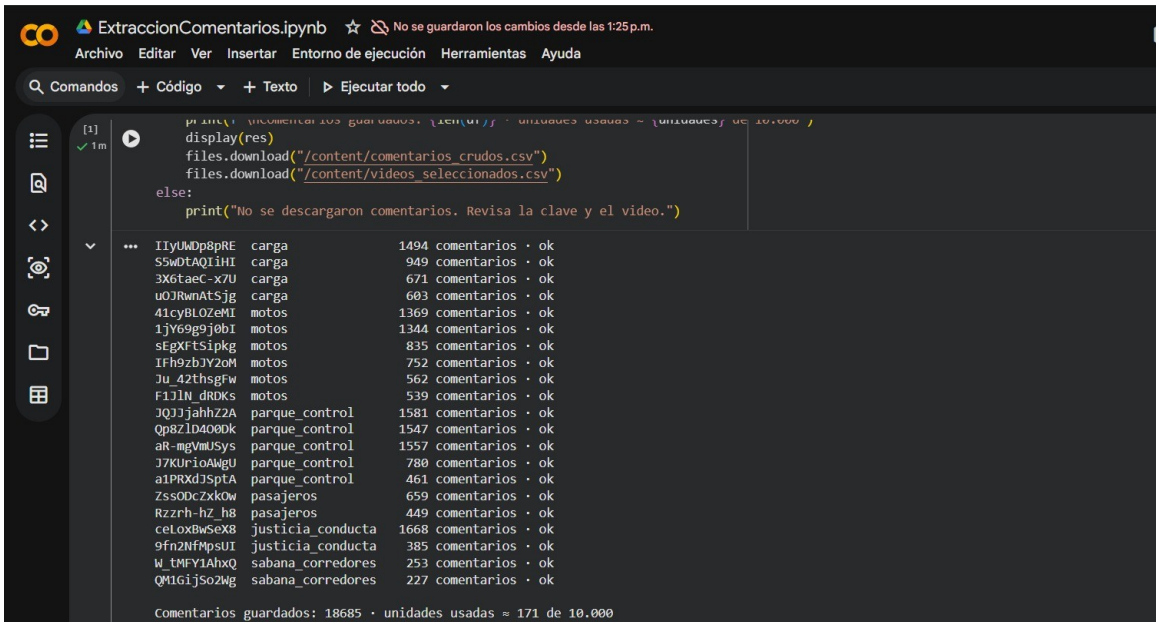
Extracción y restricciones

El script recorrió los 21 videos con un tope de 1.500 hilos por video, para que ningún video dominara el corpus, e incluyó hasta cinco respuestas por hilo, que la API entrega sin costo adicional. Los autores se reemplazaron por un código anónimo (hash SHA-256), de modo que es posible detectar duplicados sin identificar a nadie. La extracción consumió 171 de las 10.000 unidades diarias, sin ningún costo. Se encontraron tres restricciones: en una primera ejecución un video devolvió un error del servidor después de 406 comentarios (*processingFailure*), por lo que la extracción se repitió y se completó con 949 comentarios; la API solo entrega cinco respuestas

por hilo sin consultas adicionales; y para Sabana Centro no se encontraron videos con más de 300 comentarios dentro del periodo de los datos.

Figura 38

Ejecución del script de extracción en Google Colab



Nota. Salida de la celda con el número de comentarios por video y la descarga de comentarios_crudos.csv y videos_seleccionados.csv.

Preparación y limpieza

El script *scripts/limpiar_comentarios.py* aplicó, en este orden: eliminación de comentarios vacíos; normalización de entidades HTML, enlaces, menciones y marcas de tiempo, con conteo y retiro de emojis; eliminación de duplicados en el mismo video y de copias del mismo autor en otros videos; eliminación de spam y promociones; descarte de comentarios con menos de tres palabras; y conservación exclusiva del español. Además, cada comentario recibió diez banderas temáticas que lo conectan con variables del proyecto (motos, carga, infraestructura, control y autoridad, mantenimiento y antigüedad, educación y licencias, imprudencia, SOAT y costos, víctimas y familia, y justicia).

Tabla 13

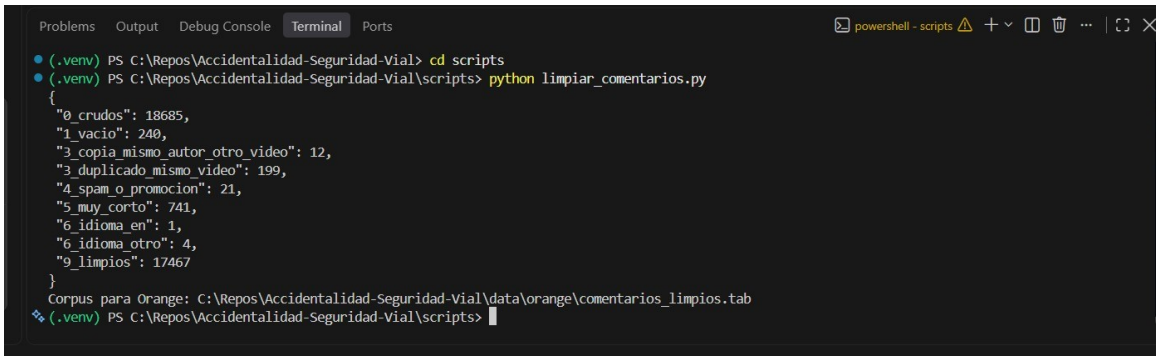
Resultado de la limpieza de comentarios

Paso	Comentarios	Decisión
Comentarios extraídos	18.685	Punto de partida (21 videos)
Vacíos o solo enlace/mención	−240	Descartados
Duplicados en el mismo video	−199	Se conserva la primera aparición
Copias del mismo autor en otros videos	−12	Se conserva la primera aparición
Spam y promociones	−21	Descartados
Menos de tres palabras	−741	Sin contenido analizable («jaja», «amén», emojis)
Otro idioma	−5	Se conserva solo el español
Corpus limpio	17.467	93,5 % de lo extraído

Nota. Conteos tomados de reporte_calidad.json, generado por scripts/limpiar_comentarios.py. Cada descarte queda registrado con su motivo en comentarios_descartados.csv.

Figura 39

Ejecución del script de limpieza y conteos del proceso

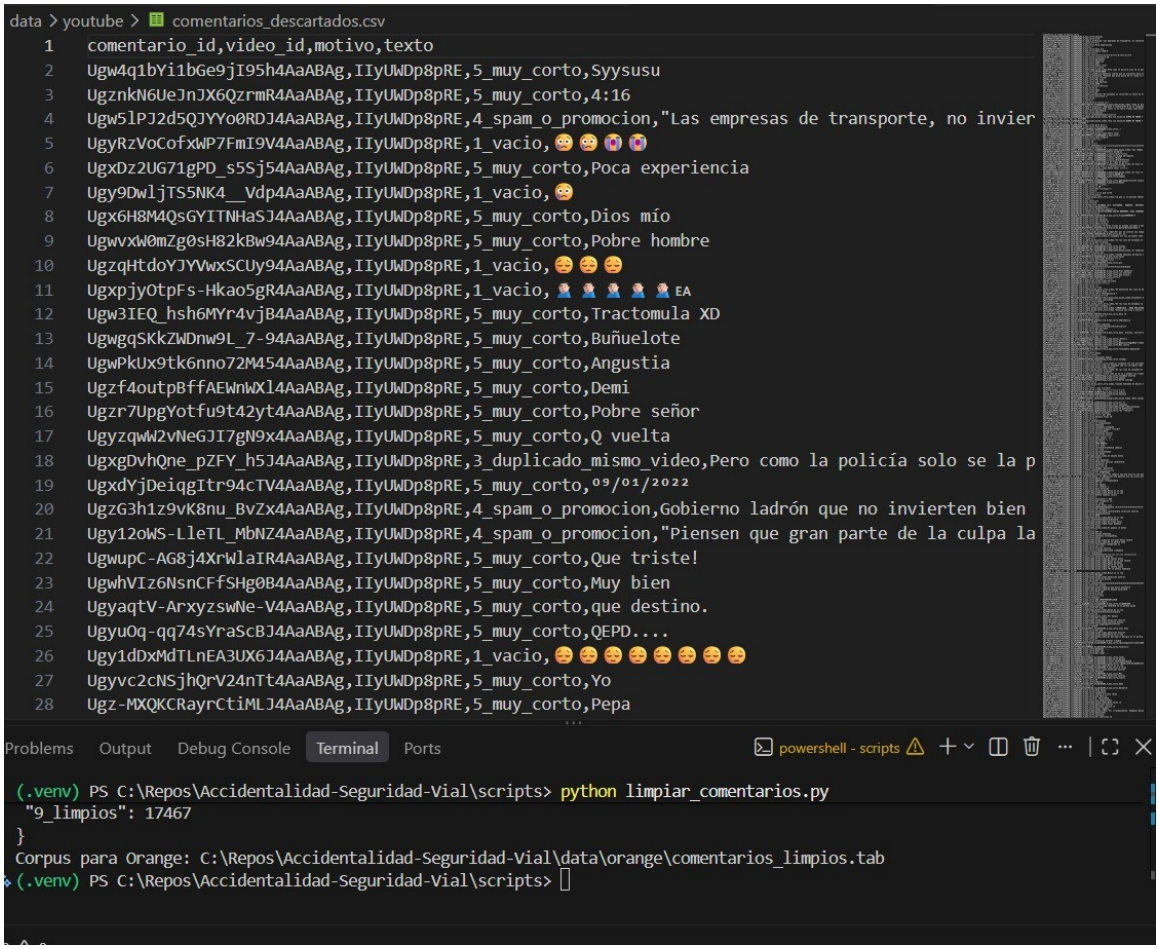


Nota. Salida de python limpiar_comentarios.py en la terminal: 18.685 comentarios crudos, conteos por criterio de descarte y 17.467 comentarios limpios guardados en data/orange/comentarios_limpios.tab.

El proceso comenzó con 18.685 comentarios. Se descartaron 1.218 registros y se conservaron 17.467 comentarios (93,5 % del total). Se generaron *comentarios_limpios.tab* para su uso en Orange, *reporte_calidad.json* con los conteos por criterio y *comentarios_descartados.csv* para revisar los registros excluidos (Figura 40).

Figura 40

Archivo de auditoría de comentarios descartados



Nota. Cada fila conserva el identificador del comentario, el video, el motivo del descarte (por ejemplo, muy_corto, vacio, spam_o_promocion o duplicado_mismo_video) y el texto, sin datos del autor.

El 6,5 % de los comentarios se descartó, sobre todo por ser demasiado cortos. Las banderas temáticas permiten una primera lectura del corpus antes de modelarlo: el 58,1 % de los comentarios activa al menos uno de los diez temas, y su distribución cambia de forma marcada según el eje del video (Tabla 14).

Tabla 14

Porcentaje de comentarios de cada eje que menciona cada tema (banderas temáticas)

Tema	Carga	Motos	Parque y control	Pasajeros	Conducta y justicia	Sabana Centro
Motos	0,7	27,1	14,3	0,1	0,8	1,6
Carga	19,4	0,8	0,8	0,2	1,2	14,0
Infraestructura y vías	24,3	4,0	4,2	3,9	0,4	18,3
Control y autoridad	11,4	9,4	14,2	2,6	4,3	8,5
Mantenimiento y antigüedad	20,6	1,0	13,3	4,6	0,2	11,7
Educación y licencia	2,7	6,3	10,6	1,6	1,6	2,1
Imprudencia	12,4	13,1	3,6	5,3	9,9	20,8
SOAT y costos	3,7	4,4	24,4	2,2	3,7	4,6
Víctimas y familia	13,9	9,5	1,6	44,5	16,7	9,8
Justicia	7,8	9,6	11,8	2,6	29,2	7,8

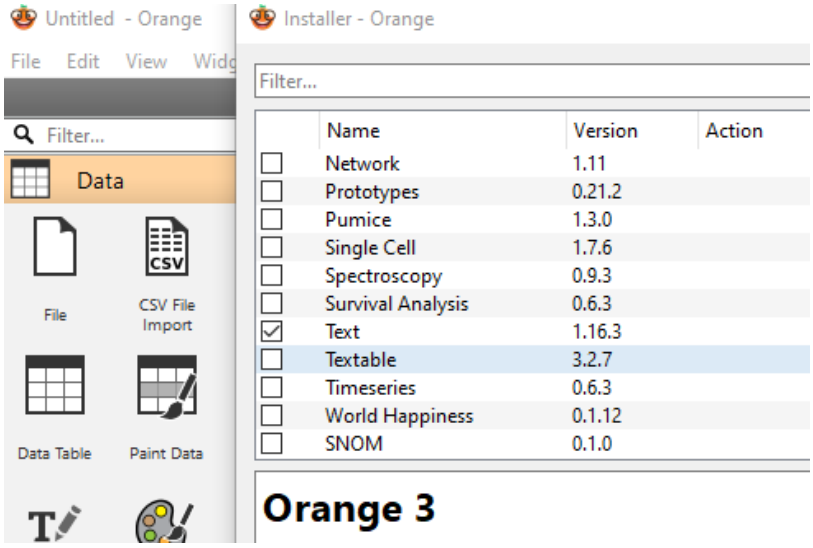
Nota. Un comentario puede activar varios temas. En negrita, el eje donde cada tema es más frecuente.

Análisis de los comentarios en Orange

El análisis se hizo en Orange Data Mining con el complemento **Text** (versión 1.16.3), que se instala desde *Options > Add-ons* (Figura 41). El corpus limpio se cargó con el widget Corpus: archivo *comentarios_limpios.tab*, idioma español, *texto* como única variable de texto y *comentario_id* como título; el resto de columnas (video, eje, tipo, año, *likes*, número de palabras, emojis y banderas temáticas) quedan disponibles para filtrar y cruzar (Figura 42).

Figura 41

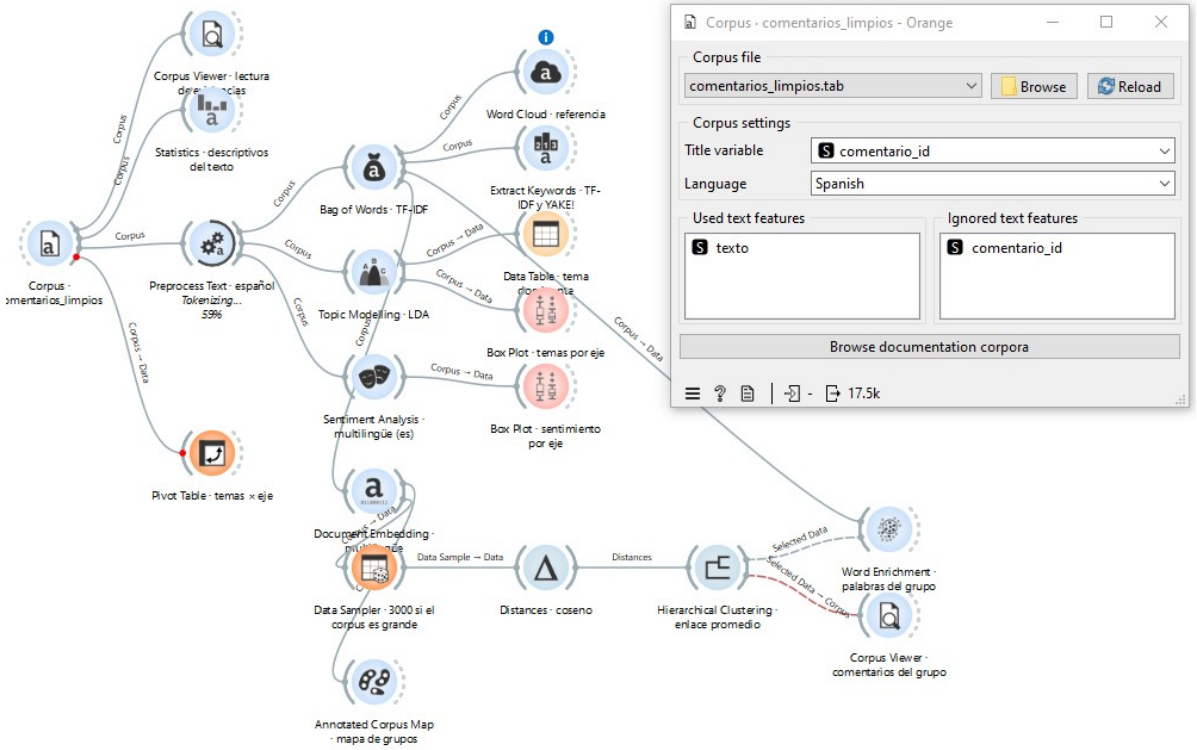
Instalación del complemento Text en Orange



Nota. Captura del instalador de complementos de Orange Data Mining con Text 1.16.3 seleccionado.

Figura 42

Widget Corpus con el archivo de comentarios limpios



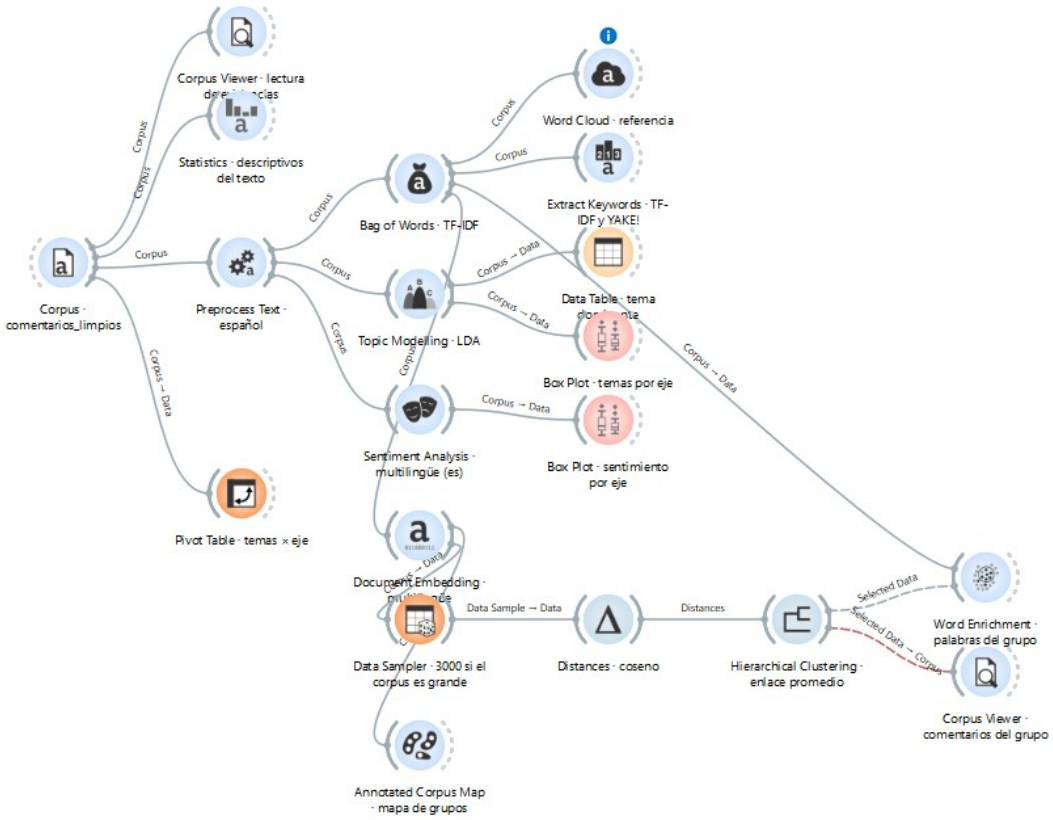
Nota. El widget reconoce 17,5 mil documentos (17.467) con texto en español.

La Figura 43 muestra el lienzo *E6_3_texto_comentarios_youtube.ows*. Del widget Corpus salen cuatro ramas. La primera explora el corpus sin transformarlo: Corpus Viewer para leer evidencias, Statistics para los descriptivos del texto y Pivot Table para cruces por eje. La segunda pasa por Preprocess Text (minúsculas, tokenización y eliminación de palabras vacías del español junto con la lista propia *stopwords_es_extra.txt*) y alimenta Bag of Words con ponderación TF-IDF, de la que dependen Word Cloud, Extract Keywords (TF-IDF y YAKE!) y Word Enrichment. La tercera aplica Topic Modelling con LDA, cuyos pesos por tema se revisan en Data Table, se cruzan con el eje en Box Plot y se exportan con Save Data. La cuarta combina Sentiment Analysis (léxico multilingüe en español) con un Box Plot por eje, y una rama de agrupamiento de comentarios con Document Embedding, Data Sampler (3.000 comentarios, para

que el cálculo de distancias sea manejable), Distances con coseno, Hierarchical Clustering con enlace promedio, Word Enrichment, Corpus Viewer del grupo seleccionado y Annotated Corpus Map.

Figura 43

Flujo de Orange para el análisis de texto



Nota. Captura del lienzo data/orange/E6_3_texto_comentarios_youtube.ows. Cada widget lleva un título que indica su función.

Exploración del corpus

Antes de modelar se leyeron comentarios con Corpus Viewer, que permite buscar por expresiones regulares y mostrar el video, el eje y el tipo de cada comentario. La lectura confirma que el corpus contiene explicaciones de causas y no solo reacciones emocionales. En la Figura 44 un usuario atribuye un siniestro a una posible falla mecánica o a la fatiga del conductor; en la

Figura 45 otro reconstruye la trayectoria de un camión en la vía Ubaté–Zipaquirá, a la altura del peaje Casablanca, es decir, en uno de los corredores de Sabana Centro.

Figura 44

Corpus Viewer: comentario que discute causas mecánicas y humanas

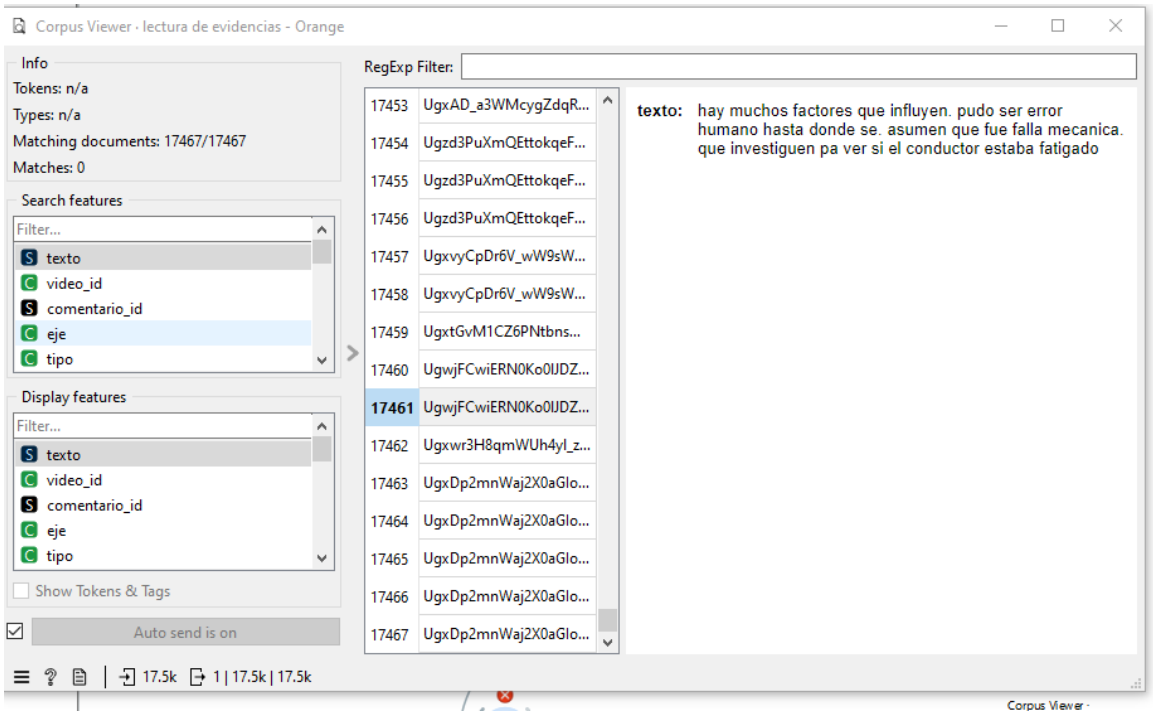
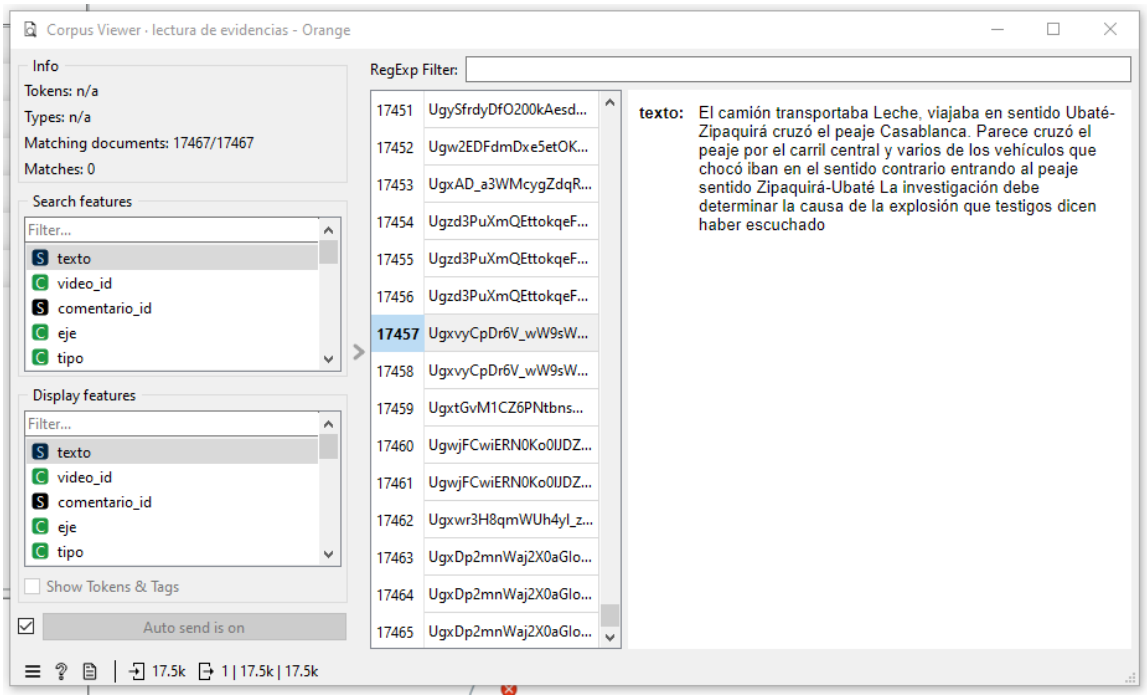


Figura 45

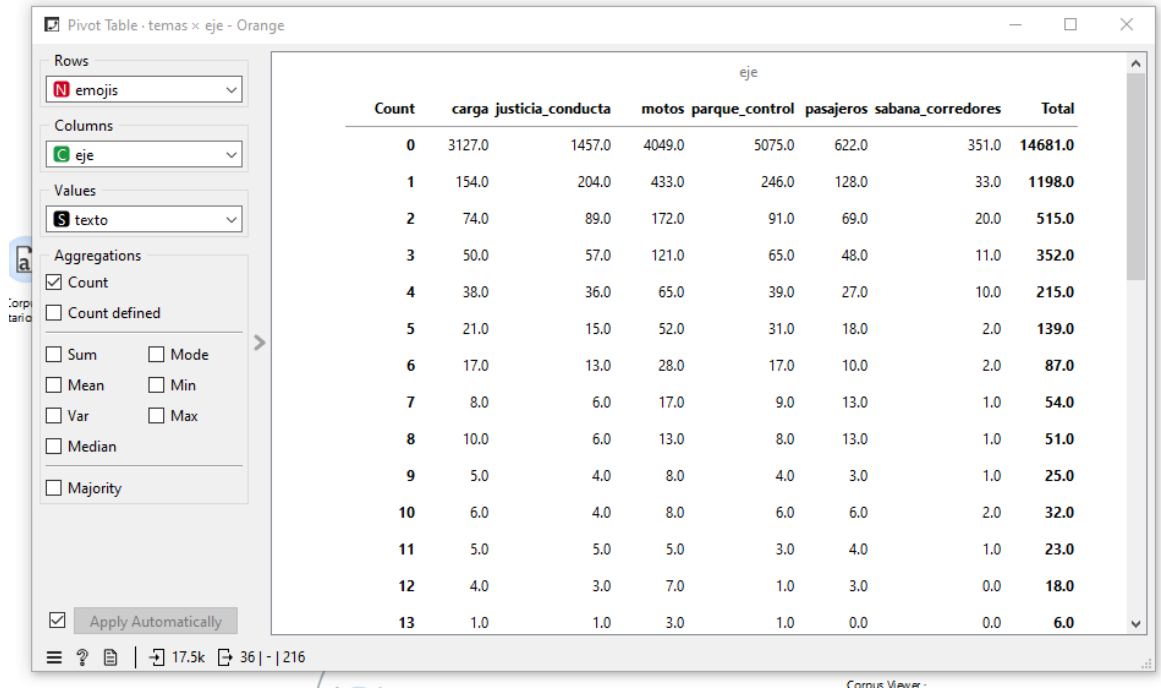
Corpus Viewer: comentario sobre un siniestro en el corredor Ubaté–Zipaquirá



La Pivot Table cruza el número de emojis de cada comentario con el eje del video. De los 17.467 comentarios, 14.681 (84,0 %) no contienen emojis; la proporción va del 63,7 % en los videos de pasajeros, donde abundan los mensajes de condolencia, al 90,6 % en los de parque y control (Figura 46). Retirar los emojis durante la limpieza no elimina, por tanto, el contenido de la mayoría de los comentarios, y el análisis puede apoyarse en el texto.

Figura 46

Pivot Table del número de emojis por comentario según el eje



Count	carga	justicia_conducta	motos	parque_control	pasajeros	sabana_corredores	Total
0	3127.0	1457.0	4049.0	5075.0	622.0	351.0	14681.0
1	154.0	204.0	433.0	246.0	128.0	33.0	1198.0
2	74.0	89.0	172.0	91.0	69.0	20.0	515.0
3	50.0	57.0	121.0	65.0	48.0	11.0	352.0
4	38.0	36.0	65.0	39.0	27.0	10.0	215.0
5	21.0	15.0	52.0	31.0	18.0	2.0	139.0
6	17.0	13.0	28.0	17.0	10.0	2.0	87.0
7	8.0	6.0	17.0	9.0	13.0	1.0	54.0
8	10.0	6.0	13.0	8.0	13.0	1.0	51.0
9	5.0	4.0	8.0	4.0	3.0	1.0	25.0
10	6.0	4.0	8.0	6.0	6.0	2.0	32.0
11	5.0	5.0	5.0	3.0	4.0	1.0	23.0
12	4.0	3.0	7.0	1.0	3.0	0.0	18.0
13	1.0	1.0	3.0	1.0	0.0	0.0	6.0

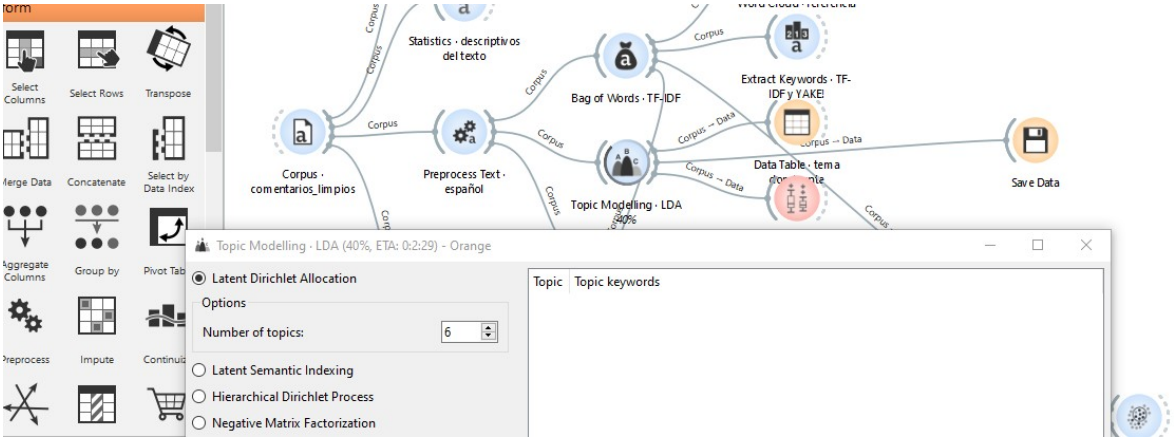
Nota. Captura de Orange Data Mining. Filas: número de emojis; columnas: eje del video; valores: conteo de comentarios.

Modelado de temas (LDA)

El widget Topic Modelling se configuró con *Latent Dirichlet Allocation* (Blei et al., 2003) y seis temas (Figura 47). Para fijar ese número, el equipo comparó como apoyo la coherencia *c_v* de modelos con 4, 5, 6, 7, 8 y 10 temas, calculada con un script de Python sobre el mismo corpus (0,650; 0,637; 0,631; 0,599; 0,587 y 0,575): los modelos de 4 y 5 temas mezclan el duelo con la discusión de causas, y desde 7 temas las conversaciones se fragmentan sin ganar claridad. La salida del widget, con el peso de cada tema en cada comentario, se exportó con Save Data, y cada comentario se asignó a su tema dominante, es decir, al de mayor peso.

Figura 47

Widget Topic Modelling configurado con LDA y seis temas



Nota. Captura de Orange Data Mining durante el entrenamiento del modelo. La salida se conecta a Data Table, Box Plot y Save Data.

Tabla 15

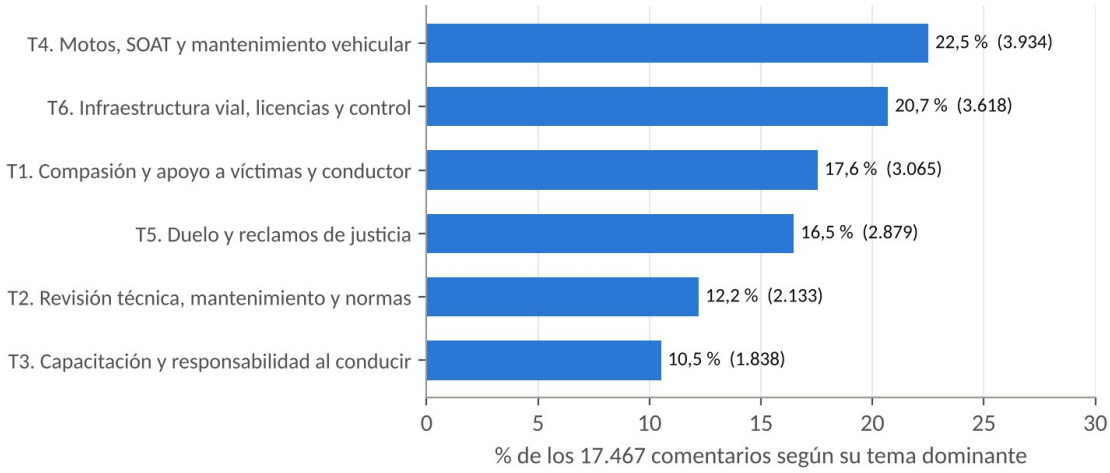
Temas identificados por el widget Topic Modelling (LDA, seis temas)

Tema	Nombre asignado	Palabras representativas	N.º	%
T4	Motos, SOAT y mantenimiento vehicular	motos, SOAT, carro, frenos, tecnomecánica	3.934	22,5
T6	Infraestructura vial, licencias y control	Colombia, conductores, licencias, vías, rampas	3.618	20,7
T1	Compasión y apoyo a víctimas y conductor	Dios, familias, víctimas, conductor, fortaleza	3.065	17,5
T5	Duelo y reclamos de justicia	justicia, familias, conductor, fortaleza, paz	2.879	16,5
T2	Revisión técnica, mantenimiento y normas	CDA, SOAT, frenos, mantenimiento, tecnomecánica	2.133	12,2
T3	Capacitación y responsabilidad al conducir	conductor, capacitación, velocidad, responsabilidad, frenos	1.838	10,5

Nota. Los identificadores T1 a T6 corresponden a Topic 1 a Topic 6 de Orange. Los nombres son una interpretación del equipo a partir de las palabras de cada tema y de la lectura de los comentarios asignados. Total: 17.467 comentarios.

Figura 48

Proporción de comentarios según su tema dominante

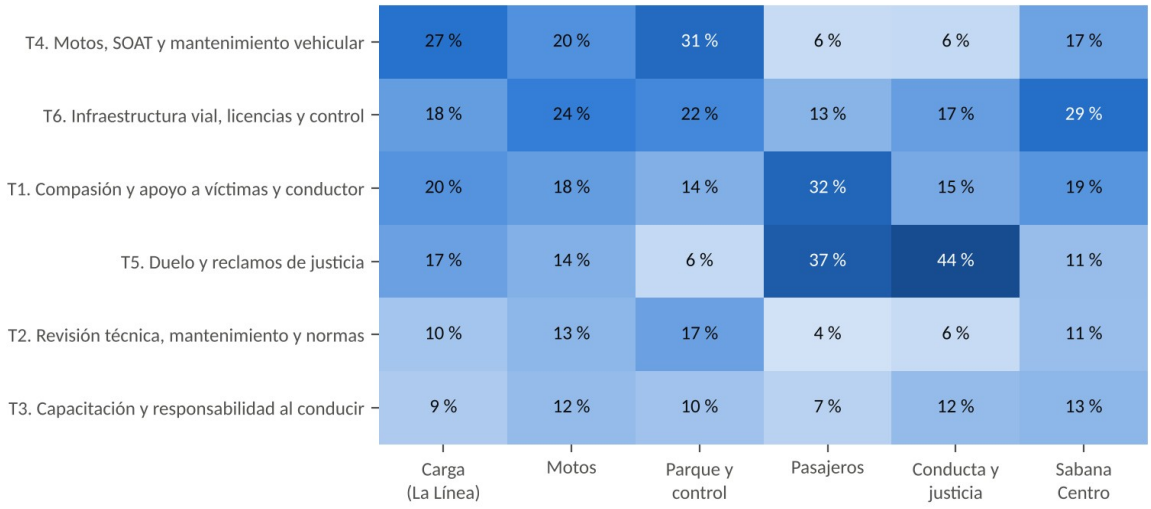


Nota. Elaboración propia con la salida de Topic Modelling exportada desde Orange (data/conocimiento_oculto/texto_resultados.json).

La conversación se reparte entre seis temas de tamaño parecido; ninguno supera la cuarta parte del corpus. Dos temas hablan del vehículo y sus controles (T4 y T2), uno de la vía y la regulación (T6), uno de la formación del conductor (T3) y dos de la dimensión humana del siniestro (T1 y T5). El peso medio del tema dominante es 0,60, lo que indica que muchos comentarios mezclan asuntos: una misma intervención puede lamentar a las víctimas y, a la vez, culpar a los frenos o a la vía.

Figura 49

Tema dominante según el eje del video



Nota. Elaboración propia con la salida de Topic Modelling. Cada columna suma 100 % y muestra cómo se reparten los comentarios de un eje entre los seis temas.

El cruce con el eje del video muestra que la conversación responde al tipo de siniestro tratado (Figura 49). El tema de duelo y justicia (T5) reúne el 43,9 % de los comentarios de conducta y justicia y el 37,0 % de los de transporte de pasajeros, donde también pesa la compasión (T1, 32,5 %). El tema de motos, SOAT y mantenimiento (T4) domina en parque y control (30,8 %) y en carga (27,3 %), y el de revisión técnica (T2) alcanza allí su valor más alto (16,9 %). El tema de infraestructura, licencias y control (T6) es el más frecuente en los videos de Sabana Centro (28,6 %) y en los de motos (23,8 %).

Para validar los nombres de los temas se cruzaron con las banderas temáticas de la limpieza, que se calcularon con reglas independientes del modelo (Tabla 16). Los resultados coinciden con la interpretación: T4 concentra las menciones a motos (26,6 %), SOAT y costos (20,3 %), mantenimiento (19,8 %) e infraestructura (14,2 %); T2, las de mantenimiento (17,1 %) y SOAT (12,9 %); T5 y T1, las de víctimas y familia (24,7 % y 17,9 %); y T6, las de justicia (15,0 %), control y autoridad (13,3 %) y educación y licencias (11,6 %).

Tabla 16

Banderas temáticas dentro de cada tema de LDA (% de los comentarios del tema)

Bandera	T1	T2	T3	T4	T5	T6
Motos	8,0	10,3	6,3	26,6	5,0	12,0
Carga	3,3	5,5	2,8	7,1	4,3	5,1
Infraestructura	4,3	7,0	5,0	14,2	3,3	10,9
Control y autoridad	5,9	11,7	7,1	15,7	5,3	13,3
Mantenimiento y antigüedad	3,2	17,1	4,4	19,8	2,5	6,4
Educación y licencia	2,7	6,8	8,1	4,8	2,8	11,6
Imprudencia	6,7	10,0	10,6	12,8	6,6	9,0
SOAT y costos	3,1	12,9	6,4	20,3	3,9	11,8
Víctimas y familia	17,9	3,1	9,0	3,3	24,7	6,3
Justicia	6,9	11,5	11,3	8,3	17,3	15,0

Nota. Elaboración propia. Un comentario puede activar varias banderas. En negrita, el tema donde cada bandera es más frecuente.

Términos distintivos por eje

Como complemento del modelo de temas se buscaron los términos que distinguen la conversación de cada eje, comparando su frecuencia dentro y fuera del eje mediante la razón de probabilidades logarítmica, calculada con un script de Python sobre el corpus limpio. En **carga**, los términos más característicos son «rampas de frenado», «frenado de emergencia», «túnel», «bajada» y «arena»; en **Sabana Centro**, «exceso de velocidad», «celular», «peajes», «tractomulas» y «buses»; en **motos**, «piruetas», «casco», «moteros» y «estupidez»; en **parque y control**, «vencida», «grúa», «póliza», «CDA» y «vigente»; en **conducta y justicia**, «influencias», «alcohol» y «haga justicia»; y en **pasajeros**, «condolencias», «fortaleza», «familias» y «jóvenes». En el corpus, el 14,4 % de los comentarios del eje de carga menciona los frenos y el 8,8 % las rampas de frenado. El flujo incluye además Extract Keywords y Word Enrichment para revisar estas palabras directamente en Orange.

Sentimiento

El flujo incluye la rama Sentiment Analysis con el léxico multilingüe en español. Como medida de referencia, el sentimiento se calculó también con la biblioteca *sentiment-analysis-spanish* de Python sobre el mismo corpus: entre el 88 % y el 94 % de los comentarios de cada eje resulta negativo, con el valor más alto en carga (94,0 %). Incluso las condolencias aparecen con tono negativo por el vocabulario de dolor que contienen. Por eso el sentimiento se usa solo para comparar ejes, no como medida absoluta: los clasificadores basados en léxico no captan la ironía ni el contexto de un siniestro.

Grupos de comentarios

La rama de Document Embedding y agrupamiento jerárquico permite seleccionar un grupo de comentarios en el dendrograma y ver sus palabras características en Word Enrichment y sus textos en Corpus Viewer. Como trabaja sobre una muestra de 3.000 comentarios, se usó como herramienta de exploración; la agrupación de comentarios que se reporta en este informe es la del tema dominante de LDA, que cubre los 17.467 comentarios.

Evidencias textuales

Las siguientes citas, transcritas sin autor y con su ortografía original, ilustran las conversaciones principales:

- «Ese tipo de vías necesitan obligatoriamente rampas de frenado o rampas de volteo para que en estos casos cualquier vehículo pueda frenar.» (eje carga)
- «Hagan RAMPAS DE FRENADO por favor! es lógico que los carros de carga en esas pendientes se quedan sin frenos... a dónde se va la plata de peajes...» (eje carga)
- «Los motociclistas son conductores violentos imprudentes y se creen los dueños de las vías.» (eje motos)

- «Cada vez más se evidencia la falta de autoridad en Medellín!! Todos los videos muestran cómo manejan las motos, sin placas, sin los elementos exigidos por tránsito.» (eje motos)
- «Lo único que veo es más plata para el gobierno o estado que cada vez se quieren lucrar más y más.» (eje parque y control)
- «Fui a cuatro (4) CDA y ninguno me lo ofreció [...] ¿Qué podemos reclamar?» (eje parque y control)
- «Cómo dejan salir un bus que tiene fallas con un grupo de personas arriesgando sus vidas.» (eje pasajeros)
- «Estos buses deberían tener un control de velocidad como lo asen las empresas de carga.» (eje Sabana Centro)

Aporte de los comentarios frente a los datos

Los comentarios aportan lo que los datos no registran: causas, responsables y percepciones. La Tabla 17 resume cómo complementan, cuestionan o amplían los resultados de los modelos supervisados y del agrupamiento.

Tabla 17

Relación entre los hallazgos de los comentarios y los resultados de los datos

Hallazgo de los comentarios	Evidencia	Relación con los datos	Tipo
En los siniestros de carga se señalan los frenos, el mantenimiento y la falta de rampas de frenado	T4 (SOAT, frenos y mantenimiento) es el tema dominante del eje carga (27,3 %); el 14,4 % menciona frenos y el 8,8 % rampas; «rampas de frenado» es el término más distintivo	Tractocamión y volqueta tienen los mayores efectos en el modelo y C5 es el grupo más letal; el conjunto de datos no registra causas	Amplía

Hallazgo de los comentarios	Evidencia	Relación con los datos	Tipo
La culpa de los siniestros de moto se atribuye al motociclista, casi nunca a la vía	En el eje motos el 9,9 % habla de imprudencia y el 5,5 % del casco, frente a 0,3 % que menciona huecos o mal estado de la vía	La moto domina el volumen, pero su letalidad por vehículo (4,8 %) es mucho menor que la de carga (21,1 %)	Contradice en parte
Los controles se perciben como costo y «negocio», no como seguridad	T4 y T2 reúnen el 47,7 % del eje parque y control; T2 alcanza allí su máximo; el 10,8 % habla de negocio, robo o plata	La flota más vieja coincide con los grupos más letales (C4 y C5); la percepción de recaudo podría favorecer la evasión	Amplía (hipótesis)
El duelo y el reclamo de justicia acompañan los casos de conducta	T5 reúne el 43,9 % del eje conducta y justicia; el 10,6 % menciona alcohol y el 9,0 % cárcel o condena	Variables ausentes del conjunto de datos (alcohol, velocidad, sanción)	Amplía
En los corredores de Sabana Centro preocupan la vía, la velocidad y las tractomulas	T6 (infraestructura, licencias y control) es el tema más frecuente del eje (28,6 %); «exceso de velocidad», «peajes» y «tractomulas» son términos distintivos	Cajicá, Cota, Chía y Sopó quedan en C1, el grupo de corredor nacional (19,1 % con muertos)	Coincide
La autoridad que atiende casi no se menciona	Solo el 4,2 % de los comentarios nombra a la policía o al tránsito, y el 1,7 % habla de corrupción	En el modelo la autoridad es la variable más informativa: actúa como indicador del tipo de vía, no del desempeño de la autoridad	Matiza

Nota. Temas: salida de Topic Modelling de Orange. Porcentajes de menciones y términos distintivos: conteos sobre el corpus limpio.

Las opiniones recolectadas corresponden a las personas que comentaron en los 21 videos seleccionados, que reaccionan a casos mediáticos concretos. No representan a toda la población del proyecto y deben leerse como indicios para generar hipótesis, no como mediciones.

Conclusiones integradas

El modelo supervisado y el agrupamiento, construidos por caminos independientes, llegan a un mismo conocimiento: **la letalidad de los siniestros depende más del tipo de vía y de la autoridad que los atiende que del vehículo en sí**. En el modelo, las variables de autoridad encabezan la relevancia y los registros de la Policía Nacional y de autoridades departamentales elevan la probabilidad de un desenlace fatal. En el agrupamiento, los municipios donde la Policía

Nacional registra casi todos los siniestros (grupos C1 y C5) tienen entre cinco y ocho veces la letalidad de los centros urbanos, sin que la gravedad haya intervenido en su formación.

Los comentarios de YouTube completan esa lectura desde la percepción ciudadana. El LDA de Orange organizó los 17.467 comentarios en seis temas: motos y mantenimiento, infraestructura y control, compasión, duelo y justicia, revisión técnica y formación del conductor. En los videos de carga y de los corredores de Sabana Centro dominan los temas del vehículo y de la vía, y aparecen con fuerza los frenos, la velocidad y la falta de rampas de frenado, es decir, causas propias de la carretera que el conjunto de datos no registra. Al mismo tiempo, la ciudadanía concentra la culpa en el motociclista, aunque los datos muestran que la moto aporta el mayor volumen pero no la mayor letalidad, y percibe los controles del parque automotor como un costo más que como una medida de seguridad.

Tabla 18

Hallazgos respaldados por evidencia

Conocimiento	**Evidencia supervisada**	**Evidencia de agrupamiento y de comentarios**
Los siniestros en vías nacionales son más letales	TipoEntidad y NivelAutoridad encabezan el Rank; Policía Nacional y autoridad departamental suben la probabilidad en el nomograma	C1 y C5 (88–93 % de registros de Policía Nacional): 19,1 % y 28,6 % con muertos, frente a 3,6 % en C2
Los vehículos de carga concentran el riesgo por vehículo	Tractocamión, volqueta y camión tienen los efectos más altos	C5 tiene 29,8 % de carga y la mayor letalidad
La moto es el mayor volumen, no la mayor letalidad	Motocicleta no figura entre los efectos más altos	C3 (72 % motos) tiene 7,0 % con muertos
Sabana Centro se comporta como corredor, no como ciudad	—	Cajicá, Cota, Chía y Sopó en C1; Zipaquirá en C2
Los patrones cambian en el tiempo	El AUC baja de 0,816 a 0,788 con datos de 2025-2026	—
Las causas en carretera (frenos, velocidad, falta de rampas) y la conducta son la explicación que da la ciudadanía	Los vehículos de carga y las vías nacionales elevan la probabilidad de muerte	Comentarios: T4 domina en carga y T6 en Sabana Centro; frenos (14,4 %) y rampas (8,8 %) en el eje carga. En C1 y C5 la letalidad es la más alta

Hipótesis que requieren validación

- **Diferencias de registro.** Antioquia, Caldas y Risaralda reducen la probabilidad de muerte; puede deberse a que sus secretarías registran muchos siniestros leves, no a un menor riesgo. Se validaría con tasas por parque automotor o con datos de Medicina Legal.
- **Antigüedad del parque.** La flota vieja coincide con las carreteras (C4 y C5); con estos datos no es posible separar el efecto de la edad del efecto de la vía.
- **Atención prehospitalaria.** La mayor letalidad en corredores podría deberse al tiempo de llegada de la atención de emergencia, variable ausente del conjunto de datos.
- **Percepción del control.** Los comentarios ven la revisión técnico-mecánica y el SOAT como recaudo; si esa percepción favorece la evasión, podría explicar parte de la letalidad de los grupos con flota vieja (C4 y C5). Requiere cruzar la vigencia de la revisión con los registros de siniestros.
- **Infraestructura de frenado.** La demanda de rampas de frenado en pendientes como La Línea sugiere que parte de la letalidad de los corredores es evitable con infraestructura; se validaría comparando tramos con y sin rampas.

Decisiones que pueden apoyarse en los resultados

- Priorizar controles de velocidad y pesaje en los municipios de los grupos C1 y C5, incluidos los de Sabana Centro sobre la Autopista Norte.
- Diseñar campañas diferenciadas: para motociclistas en las ciudades del grupo C3 y para conductores de carga en los corredores.

- Usar la regresión logística como herramienta de priorización, entendiendo sus probabilidades como un orden de riesgo y no como valores absolutos, y reentrenarla periódicamente.
- Revisar la homogeneidad del registro entre autoridades antes de comparar departamentos.

Limitaciones generales

- Los datos registran siniestros con víctimas, no exposición: sin el parque automotor ni los kilómetros recorridos no es posible calcular tasas de riesgo.
- Faltan variables explicativas del siniestro (hora, velocidad, clima, tipo de choque, uso de casco o cinturón).
- Los comentarios de YouTube provienen de usuarios que reaccionan a noticias concretas y no representan a la población.
- Los resultados de Orange pueden variar en la tercera cifra decimal entre versiones y equipos.

Evidencias del trabajo en el repositorio y publicación

El trabajo se desarrolló en la rama *Etapa-Seis* del repositorio y se integró a *main* mediante el *pull request* #12, fusionado el 12 de noviembre de 2026. La Tabla 19 resume los datos de publicación y la Tabla 20 los *commits* de cada integrante.

Tabla 19

Datos de publicación

Elemento	Valor
Repositorio público	https://github.com/lawiwi/Accidentalidad-Seguridad-Vial
Aplicación publicada	https://nicolacito.dpdns.org/
Sección de la etapa	https://nicolacito.dpdns.org/conocimiento-oculto/
Video de sustentación	https://youtu.be/1QD2VBmOwFs

Elemento	Valor
Rama e integración	Etapa-Seis, fusionada en main con el pull request #12
Flujos de Orange	data/orange/E6_1_supervisado_gravedad.ows, E6_2_clustering_municipios.ows y E6_3_texto_comentarios_youtube.ows
Scripts	scripts/preparar_datos_orange.py, scripts/extracciónc omentarios_colab.py y scripts/limpiar_comentarios.py

Tabla 20

Commits de la Etapa 6 por integrante

Usuario de GitHub	Integrante	Commits
lawiwi	Danna Angelika Ruiz Rodríguez	e3f0388 Script de preparación y datasets para Orange · 0e8c6a5 Flujo de Orange con 3 modelos y validación · c79953b Script de extracción · 09eb1d6 Expansión de la sección Flask de clustering
LauraBotia117	Laura Danniela Botia Ordoñez	4b55b0a Blueprint de Conocimiento Oculto · dc64438 Resultados de modelos, clustering y comentarios · c0f6fdc Vista interactiva de Conocimiento Oculto · e433837 Integración de la sección en la aplicación · e54a624 Flujo de clustering (E6_2)
luzangelagomezg	Luz Angela Gómez Galindo	08d7094 Script de limpieza de comentarios y preparación para Orange · ff33703 Ejecución de la limpieza de comentarios
KurogamiSenku	Nicolás Gutiérrez Reyes	c9d4143 Corpus para el flujo E6_3 · 7ee9f2a Lista de palabras vacías del flujo de comentarios · edbd03d Temas, sentimiento y grupos de comentarios · 025cd47 Integración de conclusiones con los resultados de Orange · 35dd9c3 Fusión del pull request #12

Figura 50

Commits de la Etapa 6 del 10 y 11 de noviembre de 2026



Figura 51

Commits de la Etapa 6 del 12 de noviembre de 2026

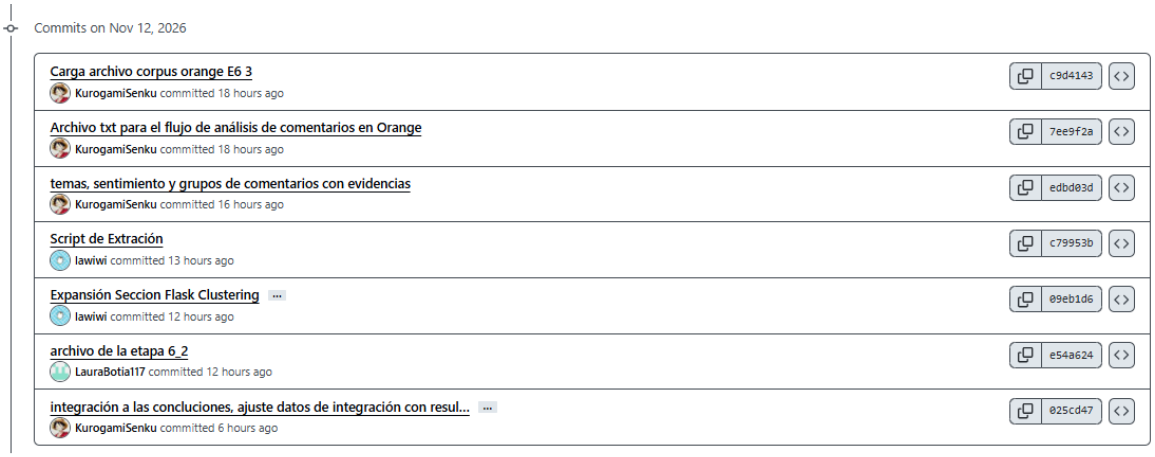


Figura 52

Pull request #12 de la rama Etapa-Seis fusionado en main



Nota. Captura de GitHub: 24 archivos modificados en la integración.

La aplicación Flask incorpora la sección «Conocimiento Oculto», accesible desde el menú principal (Figura 53). Organiza la información en pestañas: modelos supervisados, *clustering* de municipios, voz ciudadana, conclusiones e informe y video. La pestaña de *clustering* se divide en cuatro pasos (pregunta y datos, algoritmo y k, los cinco grupos, y patrones y decisiones) e incluye un buscador para consultar el grupo de cualquier municipio (Figura 54). Las cifras no están escritas a mano: se leen del archivo *data/conocimiento_oculto/resultados_etapa6.json*, de modo que coinciden con los resultados de Orange. La sección permite además consultar y descargar este informe e integra el video de sustentación.

Figura 53

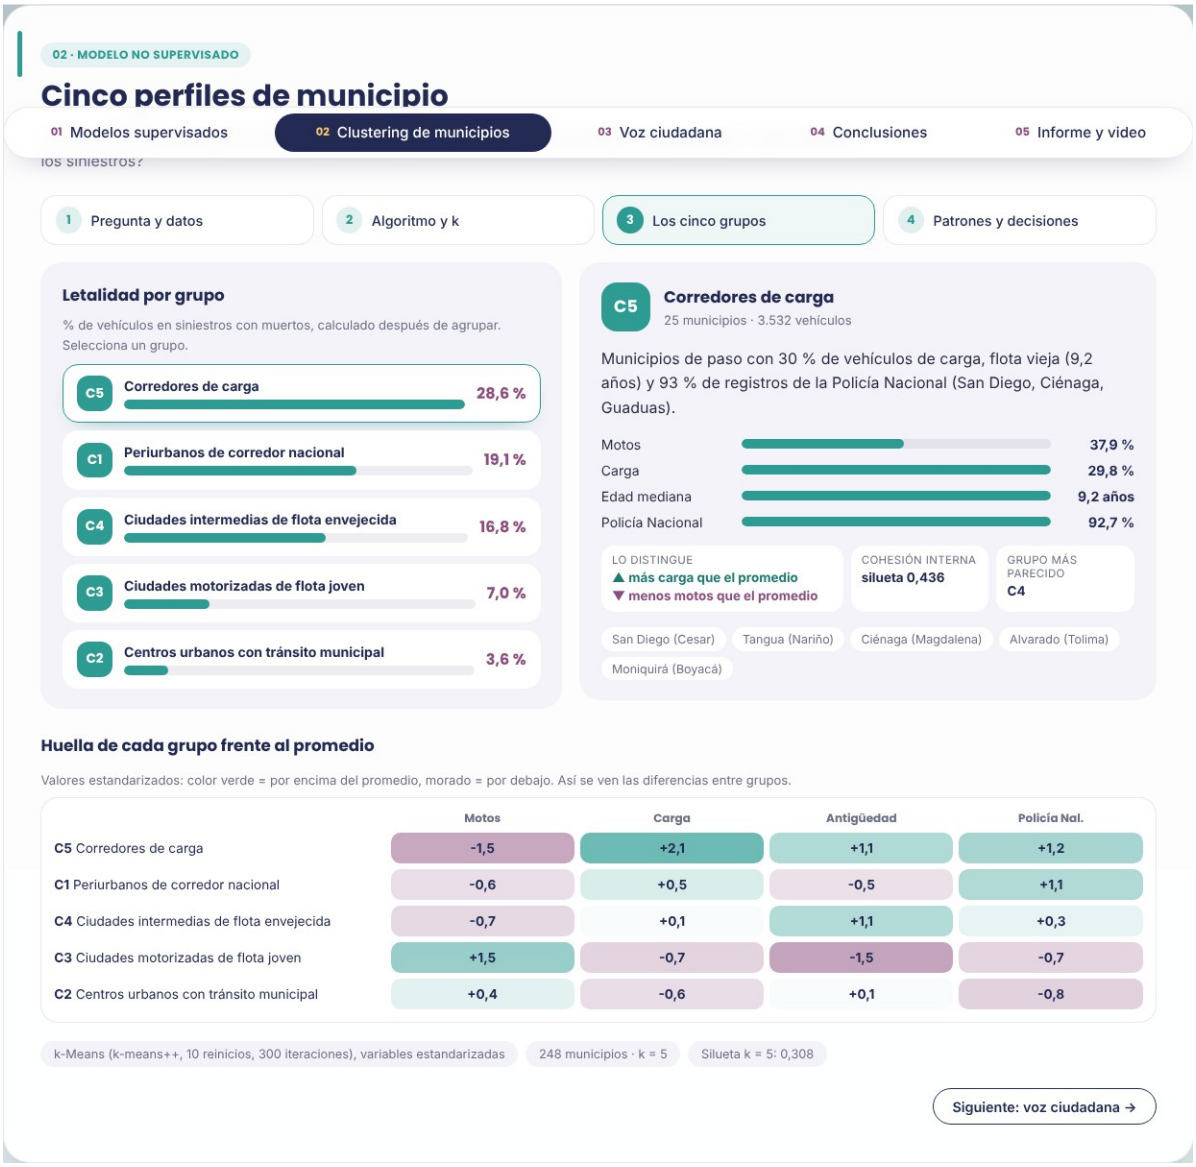
Sección «Conocimiento Oculto» de la aplicación Flask



Nota. Captura de la aplicación ejecutada en local antes de su publicación.

Figura 54

Paso «Los cinco grupos» de la pestaña de clustering



Nota. Captura de la aplicación ejecutada en local. A la izquierda, la letalidad por grupo; a la derecha, el perfil del grupo seleccionado; abajo, la huella de cada grupo frente al promedio.

Referencias

American Psychological Association. (2020). *Publication manual of the American Psychological Association* (7.ª ed.). https://doi.org/10.1037/0000165-000

Blei, D. M., Ng, A. Y. y Jordan, M. I. (2003). Latent Dirichlet allocation. *Journal of Machine Learning Research, 3*, 993–1022.

Demšar, J., Curk, T., Erjavec, A., Gorup, Č., Hočevar, T., Milutinovič, M., Možina, M., Polajnar, M., Toplak, M., Starič, A., Štajdohar, M., Umek, L., Žagar, L., Žbontar, J., Žitnik, M. y Zupan, B. (2013). Orange: Data mining toolbox in Python. *Journal of Machine Learning Research, 14*, 2349–2353.

Google. (s. f.-a). *Quota costs* [Documentación de YouTube Data API v3]. https://developers.google.com/youtube/v3/determine_quota_cost

Google. (s. f.-b). *CommentThreads: list* [Documentación de YouTube Data API v3]. https://developers.google.com/youtube/v3/docs/commentThreads/list

Ministerio de Transporte. (2026). *Vehículos involucrados en un accidente de tránsito Ley 2251-2022* [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/Transporte/VEHICULOS-INVOLUCRADOS-EN-UN-ACCIDENTE-DE-TRANSITO/6jmc-vaxk

Pallets. (s. f.). *Flask documentation*. Pallets Projects. https://flask.palletsprojects.com/

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Ruiz Rodríguez, D. A., Botia Ordoñez, L. D., Gutiérrez Reyes, N. y Gómez Galindo, L. A. (2026). *Accidentalidad-Seguridad-Vial* [Software y datos]. GitHub. https://github.com/lawiwi/Accidentalidad-Seguridad-Vial

Ruiz Rodríguez, D. A., Botia Ordoñez, L. D., Gutiérrez Reyes, N. y Gómez Galindo, L. A. (2026, 12 de noviembre). *Conocimiento oculto en la accidentalidad vial: sustentación de la Etapa 6* [Video]. YouTube. https://youtu.be/1QD2VBmOwFs

Anexo A. Ejecución y reproducibilidad

Los siguientes comandos reproducen el trabajo desde la raíz del repositorio. La clave de la API de YouTube nunca se publica: cada persona debe pegar la suya en el script de Colab antes de ejecutarlo.

```
# 1. Datos para Orange (desde la raíz del repositorio)
python scripts/preparar_datos_orange.py
# 2. Extracción: copiar scripts/extracciónconcomentarios_colab.py en Google Colab,
#    pegar la clave en API_KEY y guardar comentarios_crudos.csv en data/youtube/
# 3. Limpieza del corpus
cd scripts
python limpiar_comentarios.py
# 4. Orange Data Mining 3.38+ con el complemento Text: abrir desde data/orange/
#    E6_1_supervisado_gravedad.ows · E6_2_clustering_municipios.ows ·
E6_3_texto_comentarios_youtube.ows
# 5. Aplicación
pip install -r requirements.txt
python app.py   ->  http://127.0.0.1:5000/conocimiento-oculto/
```